


A véletlen szerepéről

Ferenci Tamás
tamas.ferenci@medstat.hu

Utoljára frissítve: 2026. február 25.


Az első példa



Az első példa

Christened.			Christened.		
Anno.	Males.	Females.	Anno.	Males.	Females.
1667	5616	5322	1689	7604	7167
68	6073	5560	90	7909	7302
69	6506	5829	91	7662	7392
70	6278	5719	92	7602	7316
71	6449	6061	93	7676	7483
72	6443	6120	94	6985	6647
73	6073	5822	95	7263	6713
74	6113	5738	96	7632	7229
75	6058	5717	97	8062	7767
76	6552	5847	98	8426	7626
77	6423	6203	99	7911	7452
78	6568	6033	1700	7578	7061
79	6247	6041	1701	8102	7514
80	6548	6299	1702	8031	7656
81	6822	6533	1703	7765	7683
82	6909	6744	1704	6113	5738
83	7377	7158	1705	8366	7779
84	7575	7127	1706	7952	7417
85	7484	7246	1707	8379	7687
86	7575	7119	1708	8239	7623
87	7737	7214	1709	7840	7380
88	7487	7101	1710	7640	7288

Az első példa




Arbuthnot gondolatmenete

- Fiú/lány arány nem fele-fele: létezik Isten (teológiai kérdés, most elfogadjuk igaznak)
- De van egy statisztikai kérdés is: tényleg nem fele-fele?
- Analógia: minden év egy pénzfeldobás, fej – fiútöbbség, írás – lánytöbbség
- Arbuthnot okfejtése:
 - ① Az, hogy 82-ből 82-ször fejet dobtunk *nem* jelenti *biztosan*, hogy a pénzérme nem szabályos (=létezik Isten), *mert* szabályos pénzérmével is lehet 82-ből 82-ször fejet dobni
 - ② De: ennek a valószínűsége extrém kicsi ($2,1 \cdot 10^{-25}$)
- Alapvető észrevétel: ha ragaszkodunk hozzá, hogy *biztos* döntést hozunk, akkor nem tudunk válaszolni...
- ...és ez *mindig* így van! Ha 820-ból 820 fej lett volna, *biztosan* akkor sem tudunk dönteni
- Az *egyetlen* biztos válasz, hogy „nem tudom”, minden máshoz *muszáj* valamennyi hibát vállalni
- Itt tehát a „hiba vállalása”, a „bizonytalan döntés” kifejezések jelentése nem inherensen negatív
- De, ami fontos: az, hogy mondunk egy számot, majd hozzátesszük, hogy „ez potenciálisan hibás”, az még nem statisztika... statisztika attól lesz, hogy a hibázás mértékét *magát* is tudjuk jellemezni!

- Vagyis a hiba jelen esetben: akkor is azt mondjuk, hogy szabálytalan a pénzérme, ha valójában szabályos
- (Igazából tehát ez egy feltételes kijelentés: feltéve, hogy szabályos a pénzérme, mi mégis azt mondjuk, hogy szabálytalan)
- Ami igazán fontos: e hiba valószínűségét tudjuk számszerűsíteni is (ld. előző megjegyzés)
- Ha csak akkor mondjuk, hogy szabálytalan a pénzérme, ha 82-ből 82 fejet dobunk (de már 81-nél is azt mondjuk, hogy „á, ez lehetett a véletlen miatt!”) akkor a fent említett nagyon kis valószínűséget vállaljuk
- Viszont ha már 81-nél is azt mondjuk, hogy „nem *hisszük*, hogy ez a véletlen miatt volt” (mondván, hogy ha szabályos lenne, akkor ez annyira valószínűtlen lenne), akkor nagyobb a hiba ($1,7 \cdot 10^{-23}$), ha már 80-nál, akkor még nagyobb ($7,0 \cdot 10^{-22}$)
- A fontos, hogy ez mind számszerűen meghatározható, mégpedig azért, mert az összes számítás úgy kezdődött, hogy „feltéve, hogy szabályos a pénzérme”, márpedig szabályosság esetén tudjuk, hogy 50% valószínűséggel dobunk fejet – ezért lesz minden kiszámolható, mert a számításhoz ez a valószínűség kell (hozzátéve még a függetlenséget)


Arbutnot gondolatmenete

Számoljuk is ki ténylegesen: ha szabályos a pénzérme, ekkora valószínűséggel dobunk mégis, pusztán a véletlen ingadozás szeszélye révén adott számú fejet 82 dobásból




Arbutnot gondolatmenete

Számoljuk is ki ténylegesen: ha szabályos a pénzérme, ekkora valószínűséggel dobunk mégis, pusztán a véletlen ingadozás szeszélye révén adott számú fejet 82 dobásból




Arbuthnot gondolatmenete

Ha csak 82-nél mondjuk, hogy szabálytalan: $2,1 \cdot 10^{-25}$ az ilyen értelmű hibavalószínűség




Arbuthnot gondolatmenete

Ha legalább 81-nél mondjuk, hogy szabálytalan: $1,7 \cdot 10^{-23}$ az ilyen értelmű hibavalószínűség




Arbuthnot gondolatmenete

Ha legalább 80-nál mondjuk, hogy szabálytalan: $7,0 \cdot 10^{-21}$ az ilyen értelmű hibavalószínűség



Arbutnot gondolatmenete

Mekkora hibát vállalunk (a „tévesen mondjuk, hogy szabálytalan a pénzérme miközben igazából szabályos” értelemben), ha adott küszöböt választunk



- Például úgy szeretnénk dönteni, hogy 5% hibát vállalunk ebben az értelemben (tehát ha szabályos a pénzérme, 5% valószínűséggel mondjuk mégis, tévesen, a véletlen ingadozás szeszélye folytán, hogy nem szabályos)
- Kiszámolható, hogy ehhez mi lesz a megfelelő határ, lásd előző ábra
- A válasz 49 (kb. 5% hibavalószínűség)
- („kb.”: a diszkréttség miatt nem lehet itt most teljesen pontosan beállítani)
- Ha abban az esetben mondjuk, hogy nem szabályos a pénzérme, ha 49-szer vagy annál többször dobunk fejet 82-ből, akkor e stratégia mellett igazolhatóan 5% lesz a valószínűsége, hogy egy szabályosra azt mondjuk, hogy szabálytalan

- Más szóval: ha nagyon sokszor kell ilyen helyzetben döntenünk, akkor a fenti szabályt követve hosszú távon az esetek 5%-ában fogunk ilyen értelmű hibát véteni
- Ha nyitunk egy pénzérme-vizsgáló üzletet, ahol azt csináljuk, hogy feldobjuk 82-szer és 49 vagy a fölött adjuk vissza azzal, hogy szabálytalan, akkor a behozott szabályos pénzérmék 5%-ra ragasztunk szabálytalan címkét
- Tehát a fenti valószínűség csak a *valójában szabályos* pénzérmék besorolásáról mond bármit is (feltételes jelleg, ugyebár!)
- Apró megjegyzés: azt nem tudjuk, hogy a behozott pénzérmék mekkora része valójában szabályos
- Ha nem 82-ször dobjuk fel a pénzérmét, akkor természetesen más lesz a döntési szabály, de a fenti módon kiszámolható minden esetben a szükséges küszöb

Mi köze ennek az orvosi vizsgálatok kiértékeléséhez?

Arbuthnot fenti modellje szinte tökéletesen megfelel a mai orvosi vizsgálatok kiértékeléséhez az esetek túlnyomó részében alkalmazott modellnek, csak a szavakat kell lecserélni:

- Pénzérme feldobása: adott beteg meggyógyul-e – fej: igen, írás: nem
- Pénzérme fej-dobási valószínűsége: gyógyulási valószínűség a gyógyszeres kezeléssel
- Tegyük fel, hogy gyógyszer nélkül a betegek fele meghal, és hogy a gyógyszer csak javítani tud (vagy nem változtat ha hatástalan, de rontani nem tud)
- (Valójában a gyógyszer nélküli arányt sem tudjuk kőbevésetten és az sem biztos, hogy csak javítani tud, de most egyszerűsítsünk, hogy a lényegre koncentráljunk)
- 82 betegem van, akinek gyógyszert adok, 82 meggyógyul – hat-e a gyógyszer?
- Tökéletes a megfeleltetés: hatástalan a gyógyszer, azaz 50% a kezelés melletti gyógyulási arány – szabályos a pénzérme; hatásos a gyógyszer, azaz 50%-nál nagyobb a gyógyulási arány – szabálytalan a pénzérme (figyelem, bármennyivel nagyobb)
- Mintanagyság – érmedobások száma
- Ugyanúgy csak hibával terhelt választ lehet hozni, *de* úgy, hogy a hiba mértéke maga is kontrollálható

Mi köze ennek az orvosi vizsgálatok kiértékeléséhez?

- Ilyen értelmű hiba: a hatástalan gyógyszert tévesen hatásosnak minősítjük
- Adjuk magát egy kérdés: ha ez hiba (ráadásul elég drámai, egy hatástalan gyógyszert törzskönyvezünk), és a mértékét mi szabjuk meg, akkor miért 5%-ot választottunk?? Miért nem 4-et? 1-et? Egymilliomodot??
- Nem beugratós a kérdés: ha ezt az értéket csökkentjük, akkor *tényleg* csökken annak a valószínűsége, hogy hatástalan gyógyszert hatásosnak hiszünk...
- ...csak épp ezzel a hibázással szemben áll egy másik: hogy egy hatásost is hatástalannak hiszünk!
- Ha csökkentjük ezt a valószínűséget (nem elég 49 betegnek meggyógyulnia, 50-nek kell, 55-nek kell, 60-nak, stb.), akkor csakugyan ritkábban fogunk hatástalan gyógyszereket törzskönyvezni, de egyre gyakrabban fogjuk még a hatásosakra is azt mondani, hogy „á, ez lehetett a véletlen miatt” – erre a gondolatra mindjárt visszatérünk
- Vegyük észre, hogy ebben a gondolkodási keretben egy fordított logika érvényesül: nem azt nézzük, hogy ezen eredmény alapján mennyire valószínű, hogy hatástalan a gyógyszer, hanem azt, hogy ha hatástalan lenne, akkor mennyire valószínű, hogy ilyen eredményt kapnánk

- Nullhipotézis (null hypothesis)
 - Kiinduló, „alapértelmezett” állításunk, amit további információ nélkül elhiszünk
 - Tipikusan azt fogalmazza meg, hogy nem találtunk semmi újat (nincs eltérés, nincs hatás, nincs különbség)
 - Szabályos a pénzérme, nincs különbség a fiú-lány arányban, nem hat a gyógyszer
 - Lényegében van egy kiindulópontunk és azt nézzük, hogy a begyűjtött adat mennyire mond neki ellent
- Ellenhipotézis (vagy alternatív hipotézis, alternative hypothesis)
 - A nullhipotézis tagadása
 - Újdonság, heuréka, találtunk valamit (van eltérés, van hatás, van különbség)
 - Nem szabályos a pénzérme, eltér a fiúk és a lányok aránya, hat a gyógyszer
- A nullhipotézis általában csak egyféleképp tud teljesülni, az ellenhipotézis több módon is (a szabályosság az az 50% fejdobási valószínűség és csak az, szabálytalan viszont sokféleképp lehet; a hatástalanság csak a 0 hatás, hatásos sokféleképp lehet, hathat kicsit is, meg nagyon is)


- Szignifikanciaszint (significance level): a célvalószínűség, ami alapján meghatározzuk a küszöb helyét; jele: α
- Elsőfajú hiba (Type I error)
 - Tévesen minősítünk hatásosnak egy hatástalan gyógyszert
 - Elvetjük a nullhipotézist, pedig igaz
 - Ha teljesülnek a próba előfeltevései, akkor a valószínűsége épp az általunk választott szignifikanciaszint, α
 - Azaz: a valószínűsége felett erős kontrollunk van (semmi egyébtől nem függ – természetesen a döntési szabály függhet például a mintanagyságtól, de az elsőfajú hiba valószínűsége nem)
- Másodfajú hiba (Type II error)
 - Tévesen minősítünk hatástalannak egy hatásos gyógyszert
 - Nem vetjük el a nullhipotézist, pedig nem igaz
 - A valószínűségének a jele: β (annak a valószínűsége, hogy nem vetjük el a nullhipotézist, feltéve, hogy nem igaz)
 - $1 - \beta$ az erő: feltéve, hogy hat a gyógyszer, mekkora valószínűséggel mutatjuk is ezt ki
 - Nincs felette erős kontrollunk

Precíz terminológia

- Szignifikáns hatás: adott szignifikanciaszinten elvetjük a nullhipotézist
 - Tartalmilag: a tapasztalt hatás – hányan gyógyultak meg – betudható-e egyszerűen a véletlen ingadozásnak, tehát, hogy a valóságban nem hat a gyógyszer és ami hatást láttunk az csak a véletlen ingadozásból fakadt, vagy olyan nagy, hogy azt feltételezzük, hogy valódi különbség van mögötte (tényleg hat a gyógyszer)
- A kérdésünk az lesz, hogy a begyűjtött adatok „eléggé” ellentmondanak-e a nullhipotézisnek (azaz: ha a nullhipotézis fennállna, akkor valószínűtlen, hogy az történjen, ami történt), ahhoz, hogy azt mondjuk, hogy „nem hisszük el” (nem kizárjuk!), hogy fennáll (vegyük észre itt is a fordított logikát!)
- Vagy azt mondjuk, hogy ez csak olyan kevésbé tér el, hogy ezt még „hajlandóak vagyunk” betudni a véletlen ingadozásnak
- (A „mit hiszünk el”, „mit vagyunk hajlandóak betudni” dolgot szabályozza a szignifikanciaszint)
- „Elfogadjuk”: elfogadjuk a nullhipotézist (azaz azt mondjuk, hogy nem találtunk hatást, pl. nem hat a gyógyszer) – bár jobb lenne úgy fogalmazni, hogy „nem tudunk elutasítani”, később majd kiderül, hogy miért
- „Elutasítunk”: elutasítjuk a nullhipotézist (azaz azt mondjuk, hogy találtunk hatást, pl. hat a gyógyszer)


Az erő és a hatásosság összefüggése

Mi az, hogy erő? Vegyük elő az ábrát hatástalanság esetén (ez ugye még nem jó az erőhöz!):




Az erő és a hatásosság összefüggése

Mi az, hogy erő? Feltéve, hogy hat a gyógyszer (50-ről 55%-ra emeli a gyógyulási arányt)




Az erő és a hatásosság összefüggése

Mi az, hogy erő? Feltéve, hogy hat a gyógyszer (50-ről 55%-ra emeli a gyógyulási arányt), mekkora valószínűséggel mondjuk mi is azt, hogy hat




Az erő és a hatásosság összefüggése

Kicsit jobban ható gyógyszer (60%)...




Az erő és a hatásosság összefüggése

Még jobban ható gyógyszer (80%)...



Az erő és a hatásosság összefüggése




- Természetesen a döntési határ minden esetben ugyanott van (hiszen azt a hatástalanság feltételezése melletti eloszlás alapján határoztuk meg, nem függ a gyógyszer hatásától!)
- Tanulság: az erő függ a gyógyszer valódi hatásától – minél hatásosabb a gyógyszer, annál nagyobb lesz (minden mást változatlanul tartva) az erő

Az erő és a mintanagyság összefüggése

- Hogyan tudjuk növelni az erőt?
 - Gyártsunk hatásosabb gyógyszert! (ez jó ötlet, de a kutatástervezés ezen a pontján a kipróbálandó gyógyszer már egy adottság)
 - Csaljunk! Azaz növeljük meg a szignifikanciaszintet (ez még jobb ötlet, csak az a baj, hogy van a fránya gyógyszerhatóság, ami ragaszkodik adott szignifikanciaszinthez)
- Mit tehetünk még?
- Intuitív ötlet: növeljük meg a mintanagyságot! („kiátlagolódnak az eltérések”)
- Csakugyan így van, nézzük meg miért


Az erő és a mintanagyság összefüggése

Az eredeti ábránk (82 beteggel)




Az erő és a mintanagyság összefüggése

A vízszintes tengelyt skálázzuk át (csak hogy összehasonlítható legyen később)




Az erő és a mintanagyság összefüggése

Ugyanez az ábra 200 beteggel (mi változott?)




Az erő és a mintanagyság összefüggése

Kicsit ható gyógyszer, 82 beteg




Az erő és a mintanagyság összefüggése

Kicsit ható gyógyszer, 200 beteg




Az erő és a mintanagyság összefüggése

Közepesen ható gyógyszer, 82 beteg




Az erő és a mintanagyság összefüggése

Közepesen ható gyógyszer, 200 beteg



Az erő és a mintanagyság összefüggése


A végeredmény:



Az erőt meghatározó tényezők

- Végeredményben tehát azt látjuk, hogy igazából két tényező hat az erőre: a gyógyszer hatásossága (hatásnagyság) és a mintanagyság
- (Sőt, valójában három, mert a szignifikanciaszint is)
- Kétféleképp is elmondható: ugyanazon hatásosság mellett nagyobb az erő, ha nagyobb a mintanagyság, *avagy* kisebb hatás is kimutatható ugyanazon erővel, ha nagyobb a mintanagyság
- „Kis hatáshoz nagy minta kell, nagy hatáshoz kis minta is elég”
- (Mármint a kimutatásához, értsd: hogy igazolni is tudjuk, hogy az nem csak a véletlen ingadozás miatt van, tehát, hogy szignifikáns)
- Nézzük meg úgy is ezt a függvényt, hogy a hatást rögzítjük, és a mintanagyságot variáljuk

Az erő és a mintanagyság összefüggése




- (A furcsa szaggatás a diszkrétség miatt van – nem tud 70,2 beteg meggyógyulni –, most ne törődjünk vele)
- Ez egy nagyon fontos dolgot lehetővé tesz: a mintanagyság racionális tervezését!
- Csak az előbbi ábrára „fordítva” nézünk rá: nem mintanagysághoz olvassuk le az erőt, hanem adott, megkívánt erőhöz – tipikusan 80% – keressük ki a mintanagyságot
- (Ellenőrző kérdés: miért 80? Miért nem 90? 99? – hiszen akkor jobb eséllyel igazolni is tudjuk, hogy hat a gyógyszer, ha tényleg hat...!)
- Figyelem: minden ilyen számítás tehát feltételes azon, hogy mekkora a gyógyszer hatása!
- Furcsa lehet, hogy előre meg kell adnom a hatást, hiszen a kutatás célja épp ennek kiszámolása, de ez olyan mint a csillagászat: minél halványabb csillagot akarok kimutatni, annál nagyobb távcső kell – úgyhogy amikor távcsövet veszünk, kell valamilyen feltételezéssel élni a csillag fényességéről
 - Vagy feltevés (például korábbi eredményekből extrapoláció, hasonló gyógyszerrel szerzett tapasztalat)
 - Vagy elvárás (mi a minimális klinikailag releváns hatás)

- (A furcsa szaggatás a diszkrétség miatt van – nem tud 70,2 beteg meggyógyulni –, most ne törődjünk vele)
- Ez egy nagyon fontos dolgot lehetővé tesz: a mintanagyság racionális tervezését!
- Csak az előbbi ábrára „fordítva” nézünk rá: nem mintanagysághoz olvassuk le az erőt, hanem adott, megkívánt erőhöz – tipikusan 80% – keressük ki a mintanagyságot
- (Ellenőrző kérdés: miért 80? Miért nem 90? 99? – hiszen akkor jobb eséllyel igazolni is tudjuk, hogy hat a gyógyszer, ha tényleg hat...!)
- Kétféleképp is elmondható: ugyanazon mintanagyság mellett nagyobb az erő, ha hatásosabb a gyógyszer, *avagy* ugyanazon erőhöz kisebb minta is elég, ha hatásosabb a gyógyszer

- Figyelem: minden ilyen számításhoz meg kell adni, hogy mekkora a gyógyszer hatása!
- Furcsa lehet, hogy előre meg kell adnom a hatást, hiszen a kutatás célja épp ennek kiszámolása, de ez olyan mint a csillagászat: minél halványabb csillagot akarok kimutatni, annál nagyobb távcső kell – úgyhogy amikor távcsövet veszünk, kell valamilyen feltételezéssel élni a csillag fényességéről
 - Vagy feltevés (például korábbi eredményekből extrapoláció, hasonló gyógyszerrel szerzett tapasztalat)
 - Vagy elvárás (mi a minimális klinikailag releváns hatás)

Az erőt meghatározó tényezők




Az erőt meghatározó tényezők


- Itt most egyszerre látjuk az összes tényezőtől való függést
- Bejött a szignifikanciaszint is
- (Ez igazából egy háromváltozós függvény, a kérdés csak az, hogy hogyan nézünk rá, milyen metszetet készítünk belőle – mit rögzítünk le, miket változtatunk, és hogyan, sínnel, vagy tengelyre rakva)
- Tanulság: ha lecsökkentjük a szignifikanciaszintet, leromlik az erő is
- Hát persze, emlékezzünk vissza mit mondtunk már a legelején: ha nagyon szigorúak vagyunk, akkor a valódi hatást is nehéz lesz észrevenni... ha ez egyik hibát csökkentjük, a másik nő

- Igazi példa: most már két csoport van, és gyógyszer nem csak javítani tud
- Profilaktikus példa: a kontrollcsoportban sem biztos, hogy mindenki elszenvedi a végpontot
- A kontrollcsoportban p_C a kockázat, a kezelés ezt 10, 20, 50, 80 illetve 90%-kal csökkenti
- Mekkora mintanagyság kell ennek a kimutatásához?
- Szokásosan $\alpha = 0,05$ szignifikanciaszint, $1 - \beta = 0,8$ erő

Egy valódi esettanulmány



Egy valódi esettanulmány




- Gondoljuk végig az eddigieket az ábrán!
- Egy plusz tanulság: annál könnyebb szignifikánsnak kimutatni valamit, minél nagyobb az abszolút különbség is a csoportok között (még ha a relatív különbség állandó is!)
- Lásd vakcinás példa:
 - Ezért hatalmasak az ilyen kísérletek
 - Persze kölcsönhat az utánkövetés hosszával (abszolút húsbavágó kérdés: lehet, hogy kevesebb alannyal is jók lennénk, ha hosszabb a vizsgálat, *vagy* ugyanannyi alannyal pontosabb eredményt kapnánk, *de* így később lenne csak eredmény...!)
 - Challenge kísérlet?

A p -érték

- A fentiek azt sugallják, hogy a szignifikanciaszinttel egy bináris döntést adunk meg („hat” – „nem hat”)
- De így semmi nem derül ki abból, hogy mennyire erős ez a döntés
- Vigyázat, az „erős” most azt jelenti: mennyire mond ellent a nullhipotézisnek (hatástalan gyógyszer), azaz mennyire vetjük el, hogy a kutatásban tapasztalt hatás pusztán a véletlen műve, miközben valódi hatás nincs
- Ne keverjük ezt össze azzal, hogy a gyógyszer mennyire hatásos, itt nem erről van szó, hanem arról, hogy a tapasztalt hatásról, *legyen az bármekkora*, mennyire biztosan tudjuk kijelenteni, hogy nem a véletlen műve – a kettő nem ugyanaz! (kis hatás is lehet nagyon biztosan nem a véletlen műve és egy nagy hatás is lehet, hogy kijöhetett véletlenül – mikor is?)
- Ötlet: ha nem csak azt adjuk meg, hogy 5%-on hat-e, hanem ilyenkor azt is, hogy 1%-on hat-e, akkor gazdagítjuk az információt (természetesen csak ennek van értelme, 10%-on felesleges megadni, hogy hat-e – miért is?)
- És 0,1%-on? Vagy ha 5-ön sem hatott akkor 10-en...? És így tovább
- Például: 82-ből 51 gyógyult meg


A p -érték

10%-os szignifikanciaszint: túl magas




A p -érték

5%-os szignifikanciaszint: még mindig kicsit magas




A p -érték

1%-os szignifikanciaszint: hopp, ezzel már túllóttünk



A p -érték

2%-os szignifikanciaszint: ez megint picit sok



A p -érték

- A pontos érték (egy lehetséges, népszerű módszerrel – a diszkréttség miatt nem egyértelmű) $p = 0,01762$
- Ez tehát az a szignifikanciaszint, ahol épp a hatásosnak minősítés és a hatástalannak minősítés határán vagyunk
- Azaz:
 - Ha ennél nagyobb szignifikanciaszintet választunk, akkor hatásosnak minősítjük a gyógyszert: ekkor enyhítjük a küszöböt, azaz balra toljuk a határt (mert nagyobb valószínűségnek kell tőle jobbra lennie; ugye a szignifikanciaszint a küszöbtől jobbra lévő valószínűség), így a tapasztalt érték a „hat” zónába kerül
 - Ha kisebbet, akkor hatástalannak minősítjük a gyógyszert: ekkor szigorítunk, jobbra toljuk a határt (mert kisebb valószínűségnek kell tőle jobbra lennie), így a tapasztalt érték a „nem hat” zónába kerül
- Ezért szokták mindig azt nézni, hogy a p kisebb-e mint 0,05, hiszen 5% a szignifikanciaszint szokásos értéke
- (Ezeket ne mechanikusan memorizáljuk, legyen mögötte a fentiekben leírt kép, hogy mi történik, és így értsük az okát!)
- Lényegében lehetővé teszi, hogy az olvasó tetszőleges, általa szimpatikusnak talált szignifikanciaszinten döntsön


A p -érték másik interpretációja

- A p -érték egyúttal egyfajta mérőszáma is annak, hogy az adatok mennyire mondanak ellent a nullhipotézisnek (mennyire erősen bizonyítják, hogy a hatás nem pusztán a véletlen ingadozás miatti – a fordított logika értelmében!)
- Így már az is látszik, hogy az erősség alatt pontosan mit ért a p -érték
- A szignifikanciaszint a határtól jobbra lévő valószínűség és a p -értékhez a határt pont a tapasztalt értékbe toljuk – magyarul a p -érték az épp a határtól jobbra lévő valószínűség!
- Tehát a p -érték azt jelenti, hogy ha a gyógyszer hatástalan lenne, akkor mennyire valószínű, hogy olyan, vagy annál is extrémebb (hatástalanságnak még jobban ellentmondó) eredmény jöjjön ki, mint ami ténylegesen kijött
- Tehát valóban, józan ésszel is, mérőszáma a fent definiált erősségnek
- (Egyedül az lehet kérdés, hogy a „vagy annál is extrémebb” kitétel miért kell, de ha végiggondoljuk, ez is logikus)
- Sajnos itt két dolog keveredik, a manapság használt kiértékelési módszertan több iskola nem teljesen konzisztens keveréke

- A fentiekben végig azzal foglalkoztunk, hogy van egy valóságra vonatkozó állításunk („a gyógyszer valódi hatása nulla, a gyógyulási arány kezelés mellett is 50%”), és annak az igazságtartalmát vizsgáltuk
- De feltehető ez a kérdés is: mit gondolunk, *mennyi* a gyógyszer hatása (pl. a kezelés melletti gyógyulási arány)...
- Ahogy az előbbi kérdésre nincs biztos igen/nem válasz, úgy erre is csak bizonytalan, potenciálisan hibával terhelt válasz adható
- Például a 82 betegből 51 gyógyult meg – mit *tippelünk*, mennyi a gyógyulási arány?
- $51/82 = 62,2\%$?
- A legjobb *tippünk* valóban ez (ezt be lehetne matematikailag is bizonyítani, ha alkalmasan definiálnánk egy tippelés jóságát, most ezzel nem foglalkozunk)...
- ...de ez akkor is csak *tipp*!


Tippelés, mert...

Ha a valódi gyógyulási arány 55%, akkor kijöhet kényelmesen az 51/82, pusztán a véletlen ingadozás miatt...




Tippelés, mert...

Ha a valódi gyógyulási arány 70%, akkor is kijöhet kényelmesen az 51/82, pusztán a véletlen ingadozás miatt...




Tippelés, mert...

...de ha a valódi gyógyulási arány 45%, akkor már nem jöhet ki kényelmesen, pusztán a véletlen ingadozás miatt az 51/82



Tippelés, mert...

...és ha a valódi gyógyulási arány 75%, akkor szintén nem jöhet ki kényelmesen, pusztán a véletlen ingadozás miatt az 51/82



Határok húzása: a konfidenciaintervallum

- Kérdés persze, hogy mit értünk az alatt, hogy „adott valódi érték esetén kényelmesen kijöhet”
- Egy lehetséges válasz: olyan érték, amire igaz, hogy az 51/82 eltérése nem szignifikáns tőle
- Tehát, ha ezt az értéket feltételezzük valódinak, és megkérdezzük, hogy ilyen valóság esetén hihető-e (adott szignifikanciaszinten!), hogy pusztán a véletlen miatt 51/82 jöjjön ki, akkor igen a válasz
- Ezen értékek halmazát úgy hívjuk, hogy konfidenciaintervallum (CI)
- Az 51/82 (62,2%) esetén ez egy népszerű eljárással számolva: 50,8% – 72,7%
- Tehát ha a valódi arány 50,8%-nál kisebb, vagy 72,7%-nál nagyobb lenne, akkor már nem lenne hihető (adott szignifikanciaszinten!), hogy pusztán a véletlen miatt 62,2%-ot kapjunk – amit ténylegesen kaptunk...
- ...de ha a valódi érték 50,8% és 72,7% között van, akkor ezekből az értékekből kényelmesen kaphatunk 62,2%-ot a véletlen ingadozás folytán
- Vegyük észre itt is a fordított logikát: nem azt kérdeztük, hogy ha kijött 62,2%, akkor lehet-e adott érték a valóság, hanem azt, hogy ha adott érték *lenne* a valóság, akkor lehet-e 62,2% amit kapunk


- A CI-t tehát jellemzi az az α szignifikanciaszint, amit használtunk a „kényelmesen kijöhet” eldöntésére
- A gyakorlatban a CI-t inkább az $1 - \alpha$ -val jellemezzük, neve: megbízhatósági szint
- Tehát a szokásos 5%-os szignifikanciaszint megfelelője a 95%-os megbízhatósági szint
- Egy hatás akkor nem szignifikáns 5%-on, ha a 95%-os megbízhatósági szintű CI-je tartalmazza a hatástalanságot (gondoljuk végig!)
- A 95%-os megbízhatósági szint egyensúlyozás: az se jó, ha azt mondjuk, hogy nagyon megbízhatóan kijelentjük, hogy szinte akárhol lehet a vizsgált jellemző, meg az sem, ha nagyon megbízhatatlanul kijelentjük, hogy szinte pontosan csak itt lehet

- A CI mögött a véletlen ingadozás (még szebb nevén: mintavételi ingadozás) van: bármi a valódi érték, a mintából kapott nem mindig az lesz, hanem ingadozik körülötte – ezért van az, hogy a mintában 62,2% nem jelenti azt, hogy a valóság is annyi
- A CI szélessége jellemzi, hogy milyen precízen tudtuk „lokalizálni” a vizsgált jellemzőt (a véletlen ingadozásra tekintettel)
- A CI kifejezi a bizonytalanságot: a 62,2%-kal (szép szóval: pontbecslés) az a baj, hogy nem mond semmit a benne lévő bizonytalanságról; miközben azt mondtuk, hogy a dolog pont attól statisztika, hogy arról is tudunk nyilatkozni – a konfidenciaintervallum ezt valósítja meg

- Mi történik, ha emeljük a mintanagyságot?
- Csökken a mintavételi ingadozás!
- (És így a CI is szűkebb lesz)


82 elemű minta

Ha a valóság 70% lenne, mennyire kényelmesen kaphatunk, pusztán a véletlen ingadozás miatt, 51/82-t, azaz 62,2%-ot? (95% CI: 50,8% – 72,7%)




2 · 82 elemű minta

Ha a valóság 70% lenne, mennyire kényelmesen kaphatunk, pusztán a véletlen ingadozás miatt, 102/164-et, azaz 62,2%-ot? (95% CI: 54,3% – 69,6%)



3 · 82 elemű minta

Ha a valóság 70% lenne, mennyire kényelmesen kaphatunk, pusztán a véletlen ingadozás miatt, 153/246-et, azaz 62,2%-ot? (95% CI: 55,8% – 68,3%)



Mintavételi hiba (variancia)

- A pusztán mintavételi ingadozásból fakadó hiba neve: mintavételi hiba
- A mintavételi hibára azt szokták mondani: *variancia* típusú hiba
- A becsült érték eltérhet a valóságtól, de ha sokszor megismételnénk a mintavételt, akkor *átlagosan* nem lenne eltérés: ingadozik ugyan az eredményünk, de legalább a jó érték körül
- ...és minél nagyobb a mintanagyság, annál kevésbé
- Tehát ez a fajta hibázás nem bináris, nem arról van szó, hogy van ilyen vagy nincs, hanem számszerűen lemérhető: *mennyire* ingadozik a mintából kapott érték annak átlaga körül (pl. mekkora a szórása: ez az ún. standard hiba)
- Azt, hogy milyen kicsi ez a variancia szokták a vizsgálat precizitásának is nevezni
- Jól bevált apparátussal – következtető statisztika: *p*-értékek, konfidenciaintervallumok stb.
– vizsgálható jellemezhető

Nem-mintavételi hiba (torzítás)

- Minden, ami nem a mintavételi ingadozásból fakad
- ...úgyhogy egyet már nagyon is láttunk eddig is: épp ilyen a confounding is!
- Egy másik tipikus példa: mi van, ha a mintát nem olyan tökéletesen választjuk (azaz nem lehet belőle következtetni a sokaságra)?
- Általános jellemzője az ilyen hibáknak, hogy még ismételt mintavétellel sem tartanak a nullába, azaz a mintából kapott értékeknek az átlaga sem a valódi érték
- Tehát: nem is a jó érték körül ingadozik az eredmény!
- Az ilyen típusú hibákat nevezzük *torzításnak* (lemérhető az átlag és a valódi érték különbségével, ennek neve az ellenség megtévesztése végett szintén torzítás)
- Sokszor keveset beszélnek róla az orvosi gyakorlatban, pedig rettentő fontos tud lenni...

- Nagyon nagy általánosságban beszélve a torzítástól félünk jobban
- Lehet a kettőt együtt is mérni: mennyire ingadozunk a jó érték körül
- Ebben benne van mindkét komponens: mennyire ingadozunk az átlag körül (variancia) és az átlag hol van a jó értékhez képest (torzítás)!
- Neve átlagos négyzetes hiba (belátható, hogy értéke a torzítás és a variancia négyzetének összege)

- Mindezek persze elméleti kérdések, olyan értelemben, hogy egyetlen minta alapján úgysem tudjuk megmondani, hogy a hibázás variancia vagy torzítás-e
- Ezért is mondtuk, hogy „képzeltbeli ismételt mintavételek” kontextusában értelmezhető
- Szebben szólva ezek vizsgálatához mind valamilyen modellt kell feltételeznünk

A nem-mintavételi hibák szerepe

- Ki szokta úgy érezni, hogy egy adott gyógyszergyár által fizetett kísérletben mindig pont az ő gyógyszere lesz a jobb? (Pl. lelkes kutatók végignézték a 4 vezető pszichiátriai újság 1992-2002 közötti összes cikkét: amikor a kísérlet szponzora a vizsgált gyógyszer gyártója volt, akkor 78% volt a sikerarány, függetlennél 48%, kompetítor által fizetettnél 28%...)
- De ez meg hogyan lehet egyáltalán? (hiszen ugyanaz a gyógyszer valakinek a saját terméke, valakinek meg a kompetítoré!)
- „Miért jobb az olanzapin mint a riszperidon, a riszperidon mint a kvetiapin és a kvetiapin mint az olanzapin?”
- Ezek tipikusan nem véletlen ingadozások, nem is direkte meghamisított eredmények, hanem a – többé vagy kevésbé jóhiszemű – nem-mintavételi hibák eredményei!

Kelly RE Jr, Cohen LJ, Semple RJ, et al. Relationship between drug company funding and outcomes of clinical psychiatric research. *Psychol Med.* 2006 Nov;36(11):1647-56.

Heres S, Davis J, Maino K, et al. Why olanzapine beats risperidone, risperidone beats quetiapine, and quetiapine beats olanzapine: an exploratory analysis of head-to-head comparison studies of second-generation antipsychotics. *Am J Psychiatry.* 2006 Feb;163(2):185-94.

- Fontos már most hangsúlyozni, hogy a mintavételi hibák kezelésére bevált apparátus (p -érték, konfidenciaintervallumok stb.) az *égegyszerű világon semmit de semmit* nem mond a nem-mintavételi hibákról!
- (Miközben simán lehet, hogy egy orvosi kutatás domináns hibaforrását ez jelenti!)

Mintavételi hiba (elkerülhetetlen de kézbe tartható, variancia típusú hiba, mintanagysággal csökken) vs. nem-mintavételi hiba (elkerülhető lehet de nehezen karakterizálható, torzítás típusú hiba, mintanagysággal nem feltétlenül csökken)