

# **Idősorelemzés**

Ferenci Tamás  
`tamas.ferenci@medstat.hu`

Utoljára frissítve: 2023. május 6.

## Tartalom

# Tartalomjegyzék

|          |  |           |
|----------|--|-----------|
| <b>1</b> | <b>Az idősorelemzés alapjai</b>  | <b>5</b>  |
| 1.1      | Az idősor fogalma, jelentősége, idősorelemzés . . . . .  | 5         |
| 1.1.1    | Az idősor fogalma . . . . .  | 5         |
| 1.1.2    | Az idősorelemzés közgazdasági jelentősége, története . . . . .                                   | 7         |
| 1.1.3    | Idősorelemzési iskolák, a módszerek felosztása . . . . .   | 8         |
| 1.2      | Idősorok jellemzői a sokaságban . . . . .  | 8         |
| <b>2</b> | <b>Determinisztikus idősorelemzés, dekompozíciós idősormodellek: trend, szezonális és ciklus</b> | <b>11</b> |
| 2.1      | Determinisztikus idősorelemzés . . . . .   | 11        |
| 2.1.1    | Alapgondolat . . . . .   | 11        |
| 2.1.2    | Determinisztikus idősormodellezés regresszióval . . . . .  | 11        |
| 2.1.3    | Trend és szezonális . . . . .  | 14        |
| <b>3</b> | <b>Idősorok szűrése</b>  | <b>17</b> |
| 3.1      | Idősorok szűrése . . . . .   | 17        |
| <b>4</b> | <b>A stacionaritás és az ergodicitás fogalma</b>   | <b>23</b> |
| 4.1      | A stacionaritás fogalma, szükségessége . . . . .   | 23        |
| 4.2      | Idősor-jellemzők mintából becslése . . . . .   | 25        |
| <b>5</b> | <b>A sztochasztikus idősormodellezési filozófia, és alapelemei</b>                               | <b>27</b> |
| 5.1      | Matematikai emlékeztető . . . . .  | 27        |
| 5.1.1    | Valószínűségszámítás emlékeztető . . . . .   | 27        |
| 5.2      | A sztochasztikus idősorelemzési iskola . . . . .   | 28        |
| 5.3      | ARMA-modellek . . . . .  | 31        |
| 5.3.1    | WN-folyamat . . . . .  | 31        |
| 5.3.2    | MA-modellek . . . . .  | 31        |
| 5.3.3    | AR-modellek . . . . .  | 33        |
| 5.3.4    | ARMA-modellek . . . . .  | 35        |
| <b>6</b> | <b>Késleltetési operátor és polinom</b>  | <b>37</b> |
| 6.1      | Matematikai emlékeztető . . . . .  | 37        |
| 6.1.1    | Algebra emlékeztető . . . . .  | 37        |
| 6.2      | Az ARMA-folyamatok mélyebb matematikája . . . . .  | 38        |
| 6.2.1    | A késleltetési operátor és a késleltetési polinom . . . . .                                      | 38        |
| 6.2.2    | ARMA-folyamatok reprezentációja késleltetési polinomokkal . . . . .                              | 40        |

|           |  |           |
|-----------|--|-----------|
| <b>7</b>  | <b>A stacionaritás tesztelése</b>                      | <b>43</b> |
| 7.1       | A stacionaritás tesztelése . . . . .                   | 43        |
| 7.1.1     | A stacionaritás teszteléséről általában . . . . .      | 43        |
| 7.1.2     | Egységgyök . . . . .                                   | 45        |
| <b>8</b>  | <b>A nemstacionaritás kezelése</b>                     | <b>49</b> |
| 8.1       | Stacionarizálás . . . . .                              | 49        |
| <b>9</b>  | <b>Box-Jenkins eljárás, előrejelzés készítése</b>      | <b>53</b> |
| 9.1       | Box-Jenkins eljárás . . . . .                          | 53        |
| 9.2       | Előrejelzés készítése . . . . .                        | 54        |
| <b>10</b> | <b>Idősorok regressziója</b>                           | <b>57</b> |
| 10.1      | Exogén változós idősormodellek . . . . .               | 57        |
| 10.1.1    | Alapgondolatok, statikus regresszió . . . . .          | 57        |
| 10.1.2    | Dinamikus regressziók . . . . .                        | 58        |
| 10.1.3    | Idősoros regressziók általános modellje . . . . .      | 60        |
| 10.2      | Idősoros regresszió becslése OLS-sel . . . . .         | 61        |
| 10.2.1    | Standard modellfeltevések . . . . .                    | 61        |
| 10.2.2    | Az OLS véges mintás tulajdonságai idősorokra . . . . . | 64        |
| 10.2.3    | Az OLS nagymintás tulajdonságai idősorokra . . . . .   | 64        |

# 1 Az idősorelemzés alapjai

## 1.1. Az idősor fogalma, jelentősége, idősorelemzés

### 1.1.1. Az idősor fogalma

**Idősor sokaságban és mintában I.**

- Mi a sokaság és a minta? – ismétlés stat 2-ből
- („Sokaságban valszám kell, mintánál statisztika”)
- **Idősor** minta értelemben: időben rendezett megfigyelések


$$\{5492, 5640, \dots, 7317\},$$

általános jelöléssel

$$\{y_1, y_2, \dots, y_T\}$$


- Az egyetlen eltérés a keresztmetszethez képest: *sorrendjük* van (hatalmas jelentősége lesz majd)

**Példa: magyar GDP (hosszú éves)**




## 1 Az idősorelemzés alapjai

### Példa: magyar GDP (negyedéves)



### Példa: OTP napi záróár



### Idősor sokaságban és mintában II.

- Sokasági definíció: valószínűségi változók indexelt halmaza (ahol az indexet „idő”-nek hívjuk):

$$\{Y_t, t \in N\}$$

- Az idősor egy időpontban tehát egy valószínűségi változó
- Itt az  $N$  tehát egy *rendezett* halmaz
- Valszámos szó: **sztochasztikus folyamat**

- Közgázban jellemzően  $N$  diszkrét, sőt véges:  $N = \{1, 2, \dots, T\}$
- A minta tehát ennek egy realizációja (természetesen), itt a neve: **trajektória**

Mivel a valószínűségi változó pedig egy függvény ( $X : \omega \rightarrow \mathbb{R}$ ), ezért a sztochasztikus folyamat igazából egy *kétváltozós* függvény:  $Y : \omega \times N \rightarrow \mathbb{R}$ . Ennek megfelelően két metszete van – úgy értve, hogy melyik paramétert rögzítjük – az egyik a trajektória, a másik egy adott időpillanathoz tartozó valószínűségi változó.

### Egyetlen realizáció (reprodukálhatatlanság) problémája I.

- Mi a különbség 1406 lakás ára és az OTP 1406 napi záróárfolyama között?
- Mi van emögött?
- A függetlenség feltevés (tarthatósága)!

### Egyetlen realizáció (reprodukálhatatlanság) problémája II.

- Elég, ha ismerjük az *egyes időpontok* eloszlásait? ( $F_{Y_1}, F_{Y_2}$  stb.)
- Ami teljes mértékben leírja az idősort: az *összes* időpont *együttes* eloszlása:

$$F_{Y_1, Y_2, \dots, Y_T}$$

- (Igazából keresztmetszetnél is ez volt, csak a függetlenségi feltevés miatt esett szét egyváltozósokra)

### Egyetlen realizáció (reprodukálhatatlanság) problémája III.

- Azaz: 1 dimenziós adatra vett 100 megfigyelés vs. 100 dimenziósra vett 1 megfigyelés!
- (Ezért nem segít az sem, ha hosszabbítjuk az idősorunkat!)
- Hogyan lehet egyáltalán így bármi becsülni...?
- 1 megfigyelésből? Az érdekes lesz...  $\rightarrow$  további feltevésekre lesz majd szükség!

## 1.1.2. Az idősorelemzés közgazdasági jelentősége, története

### Az idősorelemzés közgazdasági jelentősége

- A legtöbb közgazdasági adat *igazából* idősorként érhető el!
- Számos feladatnál időbeli a fókusz, gondoljunk a – szó szoros értelmében vett – előrejelzési kérdésekre

## Idősorelemzés a közgazdaságtanban

- Eleinte: egyszerű determinisztikus módszerek (pl. dekompozíciós modellek már a XIX. században)
- Később regresszió is, de még tekintet nélkül az idősoros jellegre
- Cochrane és Orcutt mutatott rá először 1949-ben, hogy ez nem jó ötlet
- Megindult a kutatás ennek figyelembevételére
- Box és Jenkins könyve 1970-ben fordulópont: sztochasztikus módszerek
- Korszerű eljárások és aktuális kérdések (nemstacionaritás, nemlinearitás, többváltozós módszerek, ARCH, ...)

### 1.1.3. Idősorelemzési iskolák, a módszerek felosztása

#### Az idősorelemzési módszerek csoportosítása

- Időtartomány vs. frekvenciatartomány (csak az előbbivel fogunk most foglalkozni)
- Determinisztikus vs. sztochasztikus (definíciós kavargások, most: a véletlennek van-e *folyamatépítő* szerepe; ld. később részletesen)
- Egyváltozós vs. többváltozós (+panel)

## 1.2. Idősorok jellemzői a sokaságban

### Várhatóérték- és szórásnégyzet-függvény

Emlékezzünk rá, hogy egy adott időpontban az idősor egyszerűen egy valószínűségi változó, így definiálható várható értéke, szórásnégyzete, két ilyennek a kovarianciája; ez alapján:

- Várhatóérték-függvény ( $\mu : N \rightarrow \mathbb{R}$ ):

$$\mu_t := \mathbb{E}Y_t$$

- Szórásnégyzet-függvény ( $\sigma^2 : N \rightarrow \mathbb{R}_+$ ):

$$\sigma_t^2 := \mathbb{D}^2Y_t = \mathbb{E}(Y_t - \mathbb{E}Y_t)^2 = \mathbb{E}(Y_t - \mu_t)^2 = \mathbb{E}Y_t^2 - \mu_t^2$$



**Autokovariancia- és autokorreláció-függvény**

- Autokovariancia-függvény (ACVF,  $\gamma : N \times N \rightarrow \mathbb{R}$ ):

$$\begin{aligned}\gamma_{t,s} &:= \text{cov}(Y_t, Y_s) = \mathbb{E}[(Y_t - \mathbb{E}Y_t)(Y_s - \mathbb{E}Y_s)] = \\ &\quad \mathbb{E}[(Y_t - \mu_t)(Y_s - \mu_s)] = \mathbb{E}(Y_t Y_s) - \mu_t \mu_s\end{aligned}$$

- Nyilván  $\gamma_{t,t} = \sigma_t^2$
- Autokorrelációs függvény (ACF,  $\rho : N \times N \rightarrow [-1, 1]$ ):

$$\rho_{t,s} := \text{corr}(Y_t, Y_s) = \frac{\gamma_{t,s}}{\sigma_t \sigma_s}$$

Ne feledjük: mindezekben semmi sztochasztikus nincs, teljesen közönséges – determinisztikus – függvények!

**Parciális autokorrelációs függvény (PACF)**

- Úgy viszonyul az ACF-hez mint a sima (keresztmetszeti) parciális korreláció a korrelációhoz: bizonyos változókon keresztül terjedő hatásokat szűrjük (lineárisan)
- De melyikeket?
- Ami közbeesik:  $t$  és  $s$  közti korreláció ( $s > t$ ), szűrve a  $t+1, t+2, \dots, s-2, s-1$  időpontokon keresztül terjedő hatásokat
- Kiszámítható az ACF-ek ismeretében egyszerű mátrixműveletekkel
- (Avagy: a korreláció kijön egy olyan regresszióból, aminek egyetlen magyarázó változója van, a parciális korrelációhoz pedig hozzá kell adni a közbenső időpontokat is)

**Korrelogram**

- Korrelogram: ACF és PACF együtt ábrázolva
- (Egyelőre úgy tűnik, hogy ez egy kétdimenziós függvény, ezt majd később árnyalni fogjuk – és ezért nem is ábrázoljuk most még ténylegesen)
- Jelentősége: ha ismerjük nevezetes folyamatok – elméleti – korrelogramját, akkor egy minta mögötti, azt adó folyamatra következtethetünk az alapján, hogy a minta – empirikus – korrelogramja hogyan néz ki
- (Sajnos a gyakorlatban sokszor csak hozzávetőleges lehet)



## 2 Determinisztikus idősorelemzés, dekompozíciós idősormodellek: trend, szezonalitás és ciklus

### 2.1. Determinisztikus idősorelemzés

#### 2.1.1. Alapgondolat

##### A determinisztikus idősorelemzés

- Az idősor alakulása *elvileg* függvényszerűen felírható bizonyos tényezők alapján
- Csak azért nem tudjuk tökéletesen megtenni, mert nem ismerjük e tényezőket, nem tudjuk milyen függvényformával hatnak, nem tudjuk pontosan mérni stb. ezért fogunk hibázni
- De pont: a hibának *csak* ennyi szerepe van...
- ...beállítja az aktuális időszak értéket, és kész

##### Dekompozíciós idősormodellek

- Minderre a legtipikusabb – és egyben legklasszikusabb – példát a **dekompozíciós idősormodellek** jelentik
- A legismertebb additív modell:

$$Y_t = R_t + C_t + S_t + u_t,$$

ahol  $R_t$ ,  $C_t$  és  $S_t$  a trend, a ciklus és a szezonalitás  $t$ -edik időszakbeli értéke rendre,  $u_t$  pedig a már említett eltérésváltozó

- Becslés?

#### 2.1.2. Determinisztikus idősormodellezés regresszióval


##### Regresszió alkalmazása

- Az előbbi modell teljesen természetesen becsülhető regresszióval, ha  $R_t$ ,  $C_t$  és  $S_t$  helyébe beírjuk a feltételezett – paraméteres – függvényformákat

## 2 Determinisztikus időszorelemzés, dekompozíciós időszormodellek: trend, szezonalitás és ciklus

- (Most tehát mindvégig paraméteres regressziót fogunk használni)
- Legegyszerűbb eset:  $R_t = \alpha + \beta t$ ,  $C_t = 0$  és  $S_t = 0$  (egyszerű lineáris trend)
- Az így kapott modell OLS-sel becsülhető


### Negyedéves GDP (éves) lineáris trenddel I.




|                    | Coefficient   | Std. Error         | t-ratio  | p-value |
|--------------------|---------------|--------------------|----------|---------|
| const              | -2,02165e+008 | 1,50629e+007       | -13,4214 | 0,0000  |
| EV                 | 103398,       | 7512,17            | 13,7641  | 0,0000  |
| Mean dependent var | 5161052       | S.D. dependent var | 765270,3 |         |
| Sum squared resid  | 1,50e+13      | S.E. of regression | 424924,3 |         |
| $R^2$              | 0,695356      | Adjusted $R^2$     | 0,691686 |         |
| $F(1, 83)$         | 189,4494      | P-value( $F$ )     | 3,94e-23 |         |
| Log-likelihood     | -1221,169     | Akaike criterion   | 2446,339 |         |
| Schwarz criterion  | 2451,224      | Hannan-Quinn       | 2448,304 |         |
| $\hat{\rho}$       | 0,315141      | Durbin-Watson      | 1,343686 |         |

### Negyedéves GDP (éves) lineáris trenddel II.

Mi ezzel a baj? Hibatag jól specifikált? Aligha!



### Negyedéves GDP (éves) lineáris trenddel és szezonalitással I.




## 2.1 Determinisztikus idősorelemzés

|                    | Coefficient   | Std. Error         | t-ratio  | p-value |
|--------------------|---------------|--------------------|----------|---------|
| const              | -2,04994e+008 | 1,06300e+007       | -19,2845 | 0,0000  |
| EV                 | 104985,       | 5301,64            | 19,8024  | 0,0000  |
| DNEGYEDEV_1        | -815807,      | 91469,3            | -8,9189  | 0,0000  |
| DNEGYEDEV_2        | -375072,      | 92487,9            | -4,0554  | 0,0001  |
| DNEGYEDEV_3        | -203380,      | 92487,9            | -2,1990  | 0,0308  |
| Mean dependent var | 5161052       | S.D. dependent var | 765270,3 |         |
| Sum squared resid  | 7,19e+12      | S.E. of regression | 299695,1 |         |
| $R^2$              | 0,853937      | Adjusted $R^2$     | 0,846634 |         |
| $F(4, 80)$         | 116,9271      | P-value( $F$ )     | 1,34e-32 |         |
| Log-likelihood     | -1189,928     | Akaike criterion   | 2389,855 |         |
| Schwarz criterion  | 2402,068      | Hannan-Quinn       | 2394,768 |         |
| $\hat{\rho}$       | 0,946516      | Durbin-Watson      | 0,116617 |         |


### Negyedéves GDP (éves) lineáris trenddel és szezonalitással II.

A szezonális jónak tűnik, de az alaptrendet még mindig nem sikerült megragadni:



A szezonális azért tűnik jónak, mert nincs interakció az év és a szezon között, azaz minden évben hasonló a szezonális mintázata.


### Negyedéves GDP (éves) kvadrátikus trenddel és szezonalitással I.



|                    | Coefficient   | Std. Error         | t-ratio  | p-value |
|--------------------|---------------|--------------------|----------|---------|
| const              | -2,60273e+010 | 2,61365e+009       | -9,9582  | 0,0000  |
| EV                 | 2,58613e+007  | 2,60697e+006       | 9,9201   | 0,0000  |
| DNEGYEDEV_1        | -792077,      | 61608,7            | -12,8566 | 0,0000  |
| DNEGYEDEV_2        | -375072,      | 62247,4            | -6,0255  | 0,0000  |
| DNEGYEDEV_3        | -203380,      | 62247,4            | -3,2673  | 0,0016  |
| sq_EV              | -6422,59      | 650,072            | -9,8798  | 0,0000  |
| Mean dependent var | 5161052       | S.D. dependent var | 765270,3 |         |
| Sum squared resid  | 3,21e+12      | S.E. of regression | 201704,8 |         |
| $R^2$              | 0,934664      | Adjusted $R^2$     | 0,930529 |         |
| $F(5, 79)$         | 226,0280      | P-value( $F$ )     | 2,80e-45 |         |
| Log-likelihood     | -1155,736     | Akaike criterion   | 2323,473 |         |
| Schwarz criterion  | 2338,128      | Hannan-Quinn       | 2329,368 |         |
| $\hat{\rho}$       | 0,889365      | Durbin-Watson      | 0,173391 |         |

## Negyedéves GDP (éves) kvadratikus trenddel és szezonalitással II.

Reziduumok kicsit jobbák:



### Mindezek limitációi

- *Egyrészt* el kell találni a függvényformát
- Persze modelldiagnosztika (az előbb látott grafikus módszerek és tesztek is) ott van
- (Ez igazából már keresztmetszetnél is így volt)
- Pl. a kvadratikus nyilván csak erre az időszakra jó, az általánosítóképessége botrányos lenne
- *Másrészt* a hibatag diagnosztikája bonyolultabbá válik, egy új szempont is megjelenik (autokorreláció) → később még nagyon sokat fogunk róla beszélni

### 2.1.3. Trend és szezonális

#### A trend megadása

- **Trend:** „hosszú távú alapidányzat”
- A mostani trend (determinisztikus trend) bármi lehet, amit paraméteres függvényformában megadunk; például:
  - Lineáris trend:  $a + bt$
  - Kvadratikus trend:  $a + b_1t + b_2t^2$
  - Polinomiális trend:  $a + b_1t + b_2t^2 + \dots + b_kt^k$
  - Exponenciális trend:  $ae^{bt}$
  - Aszimptotikus trend:  $c + \frac{1}{a+bt}$
  - Logisztikus trend:  $\frac{1}{c+e^{a+bt}}$
  - stb. stb.

- (Persze amelyik nem lineáris, ott vagy linearizálni kell vagy – ha ez nem lehetséges – akkor nem OLS-sel becsülni)
- Ezek mind paraméteres trendek voltak, elképzelhető nem-paraméteres trend is, a legismertebb a spline-ok használata (de ne feledjük, annak a becslése kevésbé hatásos, nem kapunk egyetlen vagy néhány számba sűrített – és jó esetben tárgyterületileg értelmezhető – eredményt, valamint az előrejelzés is problémásabb)

### Szezonalitás megadása

- **Szezonalitás:** „éven belüli mintázat”, exogén módon rögzített hosszúságú, periodikus (vs. **ciklus:** „éven túli”, nem feltétlenül exogén módon adott, ismert hosszúságú)
- A szezonáltságnál viszont tipikusabb a nem-paraméteres megadás: minden negyedévnek (hónapnak, félévnek stb.) saját paramétere van
- (Dummy-kkal, ld. később, regressziós keretbe szintén szépen illeszkednek!)
- Persze itt is elképzelhető paraméteres megadás, a legismertebb a trigonometrikus (harmonikus) függvények használata

### Dummy-kódolás szezonáltsághoz: referenciakódolás

- Az egyik szezon indikátorát elhagyjuk: **referenciakódolás**

|    | $D_{Q1}$ | $D_{Q2}$ | $D_{Q3}$ |
|----|----------|----------|----------|
| Q1 | 1        | 0        | 0        |
| Q2 | 0        | 1        | 0        |
| Q3 | 0        | 0        | 1        |
| Q4 | 0        | 0        | 0        |

- Értelmezés: eltérés a referenciacsoporthoz képest (ami az elhagyott indikátorú csoport)

### Dummy-kódolás szezonáltsághoz: kontrasztkódolás I.

- Egy másik népszerű megoldás a **kontrasztkódolás:** viszonyítsunk az *átlaghoz*!
- Ehhez hogyan kell kódolni...?

|    | $C_{Q1}$ | $C_{Q2}$ | $C_{Q3}$ |
|----|----------|----------|----------|
| Q1 | 1        | 0        | 0        |
| Q2 | 0        | 1        | 0        |
| Q3 | 0        | 0        | 1        |
| Q4 | -1       | -1       | -1       |

### Dummy-kódolás szezonálításhoz: kontrasztkódolás II.

Mert:

$$\alpha + \beta_{C_{Q_1}} + 0 + 0 = \bar{y}_{Q_1} \quad (2.1)$$

$$\alpha + 0 + \beta_{C_{Q_2}} + 0 = \bar{y}_{Q_2} \quad (2.2)$$

$$\alpha + 0 + 0 + \beta_{C_{Q_3}} = \bar{y}_{Q_3} \quad (2.3)$$

$$\alpha - \beta_{C_{Q_1}} - \beta_{C_{Q_2}} - \beta_{C_{Q_3}} = \bar{y}_{Q_4} \quad (2.4)$$

És így:

- $(1)+(2)+(3)+(4) \Rightarrow 4\alpha = \bar{y}_{Q_1} + \bar{y}_{Q_2} + \bar{y}_{Q_3} + \bar{y}_{Q_4} \Rightarrow \alpha$  tényleg a főátlag (mert azonosak voltak a csoportok elemszámai, különben ún. súlyozott kontraszt kellene)
- $(2)+(3)+(4) \Rightarrow 3\alpha - \beta_{C_{Q_1}} = \bar{y}_{Q_2} + \bar{y}_{Q_3} + \bar{y}_{Q_4} \Rightarrow \beta_{C_{Q_1}} = 3\alpha - (\bar{y}_{Q_2} + \bar{y}_{Q_3} + \bar{y}_{Q_4}) = 3\alpha - (4\alpha - \bar{y}_{Q_1}) \Rightarrow \beta_{C_{Q_1}} = \bar{y}_{Q_1} - \alpha \Rightarrow$  tényleg az átlagtól való eltérés (és hasonlóan a másik kettő)

### Dummy-kódolás szezonálításhoz: egyebek

- Az angol irodalomban az általunk kontrasztkódolásnak nevezett módszert nagyon gyakran „effect coding”-nak nevezik...
- ... a kontraszt pedig az, amikor a csoportok tetszőleges – általunk meghatározott – lineáris kombinációját teszteljük




## 3 Idősorok szűrése

### 3.1. Idősorok szűrése

#### Célunk

- Szeretnénk elkülöníteni a trendet és a ciklikus komponenseket (szezón + ciklus); ez számos közgazdasági kérdésnél fontos feladat
- Egy lehetséges megoldás: „paraméteres szűrés”, azaz előírjuk a függvényformát és regresszióval megbecsüljük
- Igazából ezt megtettük az előbb is: megadtuk a trendet (lineáris vagy kvadratikus), megadtuk a szezonaritást (ezt nem-paraméteresen), és a látott reziduum a kiszűrt ciklus (+zaj) volt, ha van ilyen
- De ez függ a függvényforma-választás helyességén; nem lehetne ilyen feltevések nélkül is megtenni?
- Hogyne, például átlagoljunk ki évenként!
- Nem a legjobb, abrupt ugrások év végén, átlagoljunk inkább folyamatosan, mintegy csúszóablakot végigtolva (így is mindig négy különböző szezon lesz benne!)

#### Motiváló példa



### Mozgóátlagolás

- Ez volt az (egyszerű) **mozgóátlag**:

$$y'_t = \frac{y_t + y_{t-1} + y_{t-2} + \dots + y_{t-p}}{p+1}$$

- (Néha nem visszafelé átlagolnak, hanem az eredmény az átlagolt ablak közepén van („centrált” mozgóátlag), a dolognak nincs nagy jelentősége: ez talán kicsit jobban néz ki, viszont jövőbeli megfigyeléseket is igényel)
- Ez azt jelenti, hogy minden megfigyelés ugyanolyan súlyú; kézenfekvő gondolat, hogy a régebbiek kevésbé számítsanak
- Például:

$$y'_t = \frac{py_t + (p-1)y_{t-1} + (p-2)y_{t-2} + \dots + y_{t-(p-1)}}{p + (p-1) + (p-2) + \dots + 1}$$

- Ez az ún. súlyozott mozgóátlag

### Exponenciális mozgóátlag

- Ökonometriában gyakoribb az exponenciális súlyozás:


$$y'_t = \alpha y_t + (1 - \alpha) y'_{t-1},$$

hiszen ez nyilván annak felel meg, hogy


$$y'_t = \alpha y_t + (1 - \alpha) \alpha y_{t-1} + (1 - \alpha)^2 \alpha y_{t-2} + \dots + (1 - \alpha)^{t-2} \alpha y_2 + (1 - \alpha)^{t-1} \alpha y_1 + (1 - \alpha)^t \alpha y_0$$

- (Az  $y_0$  kezdőértéket nekünk kell megadni, a tipikus választások:  $y_1$ , az első néhány megfigyelés átlaga, az egész idősor átlaga; a következő példákban az első 4 megfigyelés átlaga került alkalmazásra)
- Tehát az ablak egyre nyúlik (végig az egész tartomány), és a súlyok exponenciálisan csengenek le

### Negyedéves GDP exponenciális mozgóátlagolása, $\alpha = 0,1$




**Negyedéves GDP exponenciális mozgóátlagolása,  $\alpha = 0,2$**




**Negyedéves GDP exponenciális mozgóátlagolása,  $\alpha = 0,5$**

### 3 Idősorok szűrése



#### Negyedéves GDP exponenciális mozgóátlagolása, $\alpha = 0,9$



#### Lineáris szűrő

- Az egyszerű és a súlyozott mozgóátlag speciális esete annak, hogy

$$y'_t = a_0 y_t + a_1 y_{t-1} + \dots + a_p y_{t-p} = \sum_{i=0}^p a_i y_{t-i}$$

- Például egyszerű mozgóátlagra  $a_i = 1/(p+1)$
- Lényegében diszkrét konvolúció
- Ezt hívjuk lineáris szűrőnek, a tulajdonságait értelemszerűen teljes mértékben meghatározzák az  $a_0, a_1, \dots, a_p$  szűrőegyütthatók

- Roppant érdekes kérdés, hogy a szűrt idősort hogyan néz ki az eredetihez képest a szűrőegyütthatók függvényében, lehet otthon kísérletezni...

### Hodrick–Prescott-szűrő

- Különösen makroökonómiában népszerű
- Alapgondolat: a trend ( $g_t$ ) követi az idősort (azaz az  $y_t - g_t$  kicsi), de nem nagyon ugrándoza (azaz  $g_t$  sima)
- A megoldandó feladat:

$$\min_{\{g_t\}_{t=1}^T} \sum_{t=1}^T (y_t - g_t)^2 + \lambda \sum_{t=2}^{T-1} [(g_{t+1} - g_t) - (g_t - g_{t-1})]^2$$

- Első tag: mennyire követi jól az idősort a trend, második tag: mennyire „rángatózik” a trend
- A  $\lambda$  együttható határozza meg a két szempont egymáshoz viszonyított fontosságát ( $\lambda = 0$ : a trend nem kell, hogy sima legyen  $\rightarrow$  pontosan az idősort lesz;  $\lambda \rightarrow \infty$ : trend legyen tökéletesen sima, nem érdekes, hogy mennyire követi az idősort  $\rightarrow$  egyenes lesz)
- Negyedéves adatokra a tipikus választás  $\lambda = 1600$

A második tagra azt írtuk, hogy „mennyire rángatózik a trend”; később majd pontosabban is fogjuk látni, hogy ez micsoda, mert van egy nagyon konkrét tartalma.

### A HP-szűrő matematikája I.

- Az érdekes az, hogy a fenti minimalizációs feladatnak van zárt alakú megoldása!
- Legyen  $\mathbf{y}$  az  $y_t$ -k,  $\mathbf{g}$  a  $g_t$ -k vektora és legyen

$$\mathbf{Q}_{(T-2) \times T} = \begin{pmatrix} 1 & -2 & 1 & \dots & 0 & 0 & 0 \\ 0 & 1 & -2 & \dots & 0 & 0 & 0 \\ 0 & 0 & 1 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -2 & 1 & 0 \\ 0 & 0 & 0 & \dots & 1 & -2 & 1 \end{pmatrix},$$

akkor a megoldandó feladat

$$\min_{\mathbf{g}} (\mathbf{y} - \mathbf{g})^T (\mathbf{y} - \mathbf{g}) + \lambda (\mathbf{Q}\mathbf{g})^T (\mathbf{Q}\mathbf{g})$$

## A HP-szűrő matematikája II.

- Deriválva  $\mathbf{g}$  szerint:


$$-2\mathbf{y} + 2\mathbf{g} + 2\lambda\mathbf{Q}^T\mathbf{Q}\mathbf{g}$$

- Egyenlővé téve nullával és megoldva (a másodrendű feltételek teljesülnek ahhoz, hogy ez tényleg minimum legyen):

$$-2\mathbf{y} + 2\mathbf{g} + 2\lambda\mathbf{Q}^T\mathbf{Q}\mathbf{g} = 0 \Rightarrow \hat{\mathbf{g}} = (\mathbf{I} + \lambda\mathbf{Q}^T\mathbf{Q})^{-1}\mathbf{y}$$

- (A megoldás mindegyik megfigyeléstől függ)

## Negyedéves GDP HP-szűrése, $\lambda = 1600$



## A HP-szűrő kritikája

Érdekes olvasmány: Hamilton, James D. „Why You Should Never Use the Hodrick-Prescott Filter.” (2016). <http://econweb.ucsd.edu/~jhamilto/hp.pdf>.

## Egyéb szűrők

- Több szűrő viselkedése alapvetően frekvencia-tartományon érthető meg
- Trend/ciklus szétválasztás: aluláteresztő szűrés (mert a trend az, ami lassan változik, a ciklus az, ami gyorsabban, persze kérdés, hogy hol a határ)
- Igazából már az egyszerű mozgóátlag is egy aluláteresztő szűrő volt!
- Vagy: LOESS-használata (STL-dekompozíció)

## 4 A stacionaritás és az ergodicitás fogalma

### 4.1. A stacionaritás fogalma, szükségessége

#### Az alapprobléma

- Egyetlen realizáció problémája
- Hogyan lehet egyetlen mintából bármit megbecsülni? Nyilván sehogy...
- És ezen ráadásul – ugyebár – a hosszabb megfigyelés sem segít
- A megoldás: valamilyen plusz-feltevés kell!

#### Jön a jótündér

- Mondjuk egy jótündér megsúgja nekünk, hogy minden időpontban (ami ugye egy valószínűségi változó) ugyanaz a várható érték:

$$\mu_t \equiv \mu$$

- ( $A \equiv$  természetesen azt jelenti, hogy  $\forall t$ -re)
- Ez tehát egyfajta *eltolásinvariancia*; írhattuk volna, teljesen egyenértékűen azt is, hogy  $\mu_t = \mu_s$ , vagy azt is, hogy  $\mu_t = \mu_{t+h}$  (most elég nyakatekert, de később ez lesz a jobb)
- Ekkor már ezt az – immár létező – *közös* várható értéket, igaz *csak ezt*, de ezt meg tudjuk becsülni mintából!
- Ehhez – de csak ehhez! – „összeönthetőek” a különböző időponthoz tartozó megfigyelések (igazából ehhez még valami további dolog is kell, de erről majd később, most fogadjuk el, hogy megvalósítható)

- Hiszen:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T y_t$$

- Menjünk tovább...

### További jótüindérek

- Ha  $\sigma_t^2 \equiv \sigma^2$  akkor létezik közös szórásnégyzet, és becsülhető:  $\widehat{\sigma^2} = \frac{1}{T} \sum_{t=1}^T (y_t - \widehat{\mu})^2$  (torzított, de aszimptotikusan torzítatlan, továbbá konzisztens)
- Menjünk tovább...
- Ha létezik az  $F_{Y_i} \equiv F$  közös eloszlás, akkor  $\widehat{F}$  becsülhető (pl. hisztogrammal)
- Menjünk tovább...
- Két változónál is az eltolásinvarianciát akarjuk megtartani:  $\gamma_{t,s}$  legyen ugyanaz mint  $\gamma_{t+h,s+h}$
- De gondoljuk végig, ez magyarul azt jelenti, hogy  $\gamma_{t,s}$  csak a  $t - s$ -től függ!
- Ez esetben becsülhető:  $\widehat{\gamma}_k = \frac{1}{T-k} \sum_{t=1}^{T-k} (y_t - \widehat{\mu})(y_{t+k} - \widehat{\mu})$
- Menjünk tovább...
- $F_{Y_t, Y_s} = F_{Y_{t+h}, Y_{s+h}}$ , minden  $s, t, h$ -ra, akkor a kétváltozós eloszlás komplettül becsülhető

### És végül...

- Az utolsó, immár tényleg mindent lefedő szint:  $F_{Y_{t_1}, Y_{t_2}, \dots, Y_{t_k}} = F_{Y_{t_1+h}, Y_{t_2+h}, \dots, Y_{t_k+h}}$  minden értelmes  $k$ -ra,  $t_1, t_2, \dots, t_k$ -ra és  $h$ -ra
- Ennek a neve: **erős stacionaritás**
- Ez az a feltevés, ami a keresztmetszethez hasonló becsülhetőséget tesz lehetővé annak ellenére is, hogy idősorban vagyunk
- A keresztmetszet azért volt egyszerűbb, mert a függetlenséget feltettük, de itt most erről szó nincs: pont az a lényeg, hogy úgy teremtettük meg a keresztmetszethez hasonló becsülhetőséget, hogy semmilyen függetlenséget nem kellett feltételeznünk – szerencsére, mert annak ugye nem lenne értelme (persze a függetlenség implikálja az erős stacionaritást)
- Viszont: rengeteget követel, elméleti kezeléshez jó, de gyakorlatban nagyon nehéz ellenőrizni a teljesülését
- Éppen ezért gyengítsük kicsit...



**A gyenge stacionaritás**

- Mint az erős stacionaritás, de
  - csak  $k = 1, 2$ -re
  - teljes eloszlás-egyezőség helyett csak első két momentumban egyezőséget követelünk meg
- Mi adódik ebből?
  1.  $\mu_t \equiv \mu$
  2.  $\sigma_t^2 \equiv \sigma^2$
  3.  $\gamma_{t,s} \equiv \gamma_{t-s}$
- (Valójában a 2. feltétel redundáns, hiszen  $\gamma_{t,t} = \sigma_t^2$ )
- A továbbiakban, ha mást nem mondunk, stacionaritás alatt mindig ezt a **gyenge (vagy kovariancia-) stacionaritást** értjük

**A stacionaritás tesztelése**

- A fentiek már adnak egy – teljesen szubjektív – módszert a stacionaritás tesztelésére: nézzünk rá az idősorra, az 1. és 2. feltétel megítélhető
- Ez a „grafikus tesztelés” persze abszolút szubjektív
- Később látni fogunk objektív módszert (statisztikai próbát) is

**4.2. Idősor-jellemzők mintából becslése****Egy gondolat a mintából történő becslésekről**

- A már látott mintából történő becsléseknél ( $\widehat{\mu}$ ,  $\widehat{\sigma^2}$ ,  $\widehat{\gamma_k}$  stb.) ne feledjük el, hogy mindezeket mind terheli a mintavételi ingadozás, az abból fakadó mintavételi hiba
  - ...konfidenciaintervallum szerkeszthető a valódi értékre
  - ...tesztelhető nevezetes értékre vonatkozó hipotézis
- Ez utóbbi tipikus példája az autokorrelálatlanság ( $H_0 : \rho_k = 0$  vs.  $H_1 : \rho_k \neq 0$ )
- Nem túl kis mintaméretnél már jó a normális approximáció:  $\widehat{\rho_k} \sim \mathcal{N}(\rho_k, 1/T)$ , így

$$\frac{\widehat{\rho_k}}{1/\sqrt{T}} \stackrel{H_0}{\sim} \mathcal{N}(0, 1)$$

### Autokorrelálatlanság tesztelése: Ljung–Box-teszt

- Nagyon sok esetben grafikusan is feltüntetik a korrelogramon az autokorrelációra vonatkozó  $\pm z_{1-\alpha/2} \frac{1}{\sqrt{T}}$  kritikus értékeket
- De vigyázat: ez a *teljes* autokorrelálatlanság ( $H_0 : \rho_1 = \rho_2 = \dots = \rho_M = 0$ ) tesztelésére nem alkalmas!
- (Többszörös összehasonlítások helyzete,  $\alpha$ -infláció)
- Legnépszerűbb teszt erre: Ljung–Box-teszt:

$$Q = T(T+2) \sum_{k=1}^M \frac{\hat{\rho}_k^2}{T-k} \stackrel{H_0}{\sim} \chi_M^2$$

- $M$  megválasztása kérdés (ha túl kicsi, elnézhetünk egy magasabbrendű autokorrelációt, ha túl nagy, eltérhetünk a  $\chi^2$  eloszlástól)!
- Tipikus alkalmazás majd: modelldiagnosztikában

### Autokorrelálatlanság tesztelése: LM-tesztek

- A Ljung–Box-teszttel komoly elméleti agályok vannak (ld. Maddala, 13.5 vagy Hayashi 2.10)
- Ennek ellenére teljesen általánosan használják...
- Lehetséges alternatíva: LM-elvű tesztek, például a Breusch–Godfrey-teszt a már említett modelldiagnosztikai helyzetben

## 5 A sztochasztikus idősormodellezési filozófia, és alapelemei: a fehérzaj-, az AR-, az MA- és ARMA-folyamatok

### 5.1. Matematikai emlékeztető

#### 5.1.1. Valószínűségszámítás emlékeztető

##### Várható érték

Ki fogjuk használni a következőket:

- A várható érték lineáris:  $\mathbb{E}(\sum_i X_i) = \sum_i \mathbb{E}X_i$
- A várható érték lineáris:  $\mathbb{E}(cX) = c\mathbb{E}X$
- Konstans várható értéke saját maga:  $\mathbb{E}c = c$

##### Szórásnégyzet

Ki fogjuk használni a következőket:

- A szórásnégyzet nem lineáris:  $\mathbb{D}^2(\sum_i X_i) = \sum_i \mathbb{D}^2 X_i$  ha  $X_i$ -k (páronként) korrelálatlanok (szemben a várható értékkel, ez *nem* mindig igaz!); ne feledjük, a függetlenség implikálja a korrelálatlanságot
- A szórásnégyzet nem lineáris:  $\mathbb{D}^2(cX) = c^2 \mathbb{D}^2 X$
- Konstans szórásnégyzete nulla:  $\mathbb{D}^2 c = 0$

##### Kovariancia és korreláció

Ki fogjuk használni a következőket:

- A kovariancia/korreláció bilineáris:  $\text{cov}(\sum_i X_i, \sum_j Y_j) = \sum_i \sum_j \text{cov}(X_i, Y_j)$
- A kovariancia/korreláció bilineáris:  $\text{cov}(aX, bY) = ab \text{cov}(X, Y)$
- Konstans mindennel korrelálatlan:  $\text{cov}(c, X) = 0$
- Az önkovariancia a variancia:  $\text{cov}(X, X) = \mathbb{D}^2 X$

## 5.2. A sztochasztikus idősortelemzési iskola

### Filozófiai alapok

- Determinisztikus (például dekompozíciós idősortmodellek) vs. sztochasztikus idősortelemzés
- A determinisztikus iskolában is van – természetesen – véletlen, csak a szerepe más: pusztán arra korlátozódik, hogy az *adott időszaki* értéket beállítsa
- A sztochasztikus iskolában ezzel szemben a véletlen az *egész későbbi* lefutást befolyásolja, a véletlennek „folyamatépítő szerepe” van
- Lássunk egy példát, hogy jobban megértsük mit jelentenek ezek a kissé homályos megfogalmazások!

### Példa a két iskolára

- Az egyik idősortunk – sokasági modellel megadva – legyen

$$Y_t^{(D)} = \alpha t + u_t,$$

ahol  $\alpha$  konstans,  $u_t \sim \mathcal{N}(0, \sigma^2)$  függetlenül

- A másik modell legyen

$$Y_t^{(S)} = Y_{t-1}^{(S)} + \alpha + u_t,$$

ahol  $\alpha$  és  $u_t$  mint előbb,  $Y_0^{(S)}$  pedig legyen 0

- A további elemzésekhez hasznos lesz a következő átalakítás:

$$\begin{aligned} Y_t^{(S)} &= Y_{t-1}^{(S)} + \alpha + u_t = \left( Y_{t-2}^{(S)} + \alpha + u_{t-1} \right) + \alpha + u_t = \\ &= \left[ \left( Y_{t-3}^{(S)} + \alpha + u_{t-2} \right) + \alpha + u_{t-1} \right] + \alpha + u_t = \dots = \alpha t + \sum_{i=1}^t u_i \end{aligned}$$

- Hasonlítanak is, meg nem is...

### Hasonlóság

Számítsuk ki a  $\mu_t$  várható érték függvényeket:

$$\mu_t^{(D)} = \mathbb{E}(\alpha t + u_t) = \mathbb{E}(\alpha t) + \mathbb{E}(u_t) = \alpha t + 0 = \alpha t$$

$$\mu_t^{(S)} = \mathbb{E}\left(\alpha t + \sum_{i=1}^t u_i\right) = \alpha t + \sum_{i=1}^t 0 = \alpha t$$


**Különbség**

Nézzük most meg a  $\sigma_t^2$  szórásnégyzet függvényeket:


$$\begin{aligned}\sigma_t^{2(D)} &= \mathbb{D}^2(\alpha t + u_t) = \mathbb{D}^2(\alpha t) + \mathbb{D}^2(u_t) = 0 + \sigma^2 = \sigma^2 \\ \sigma_t^{2(S)} &= \mathbb{D}^2\left(\alpha t + \sum_{i=1}^t u_i\right) = \mathbb{D}^2(\alpha t) + \mathbb{D}^2\left(\sum_{i=1}^t u_i\right) = 0 + \sum_{i=1}^t \sigma^2 = \\ &= t\sigma^2\end{aligned}$$

**Az igazi eltérés a viselkedésben**


- Ennek sokkal mélyebb magyarázatát kapjuk, ha arra gondolunk, hogy a viselkedésük miben más
- Segítség: kidobunk egy nagyon deviáns  $u_t$ -t (pl  $\sigma^2 = 1$  mellett  $+5$ -öt vagy  $-5$ -öt), miben tér el a két idősor későbbi viselkedése?
- Ez a két extrém véglet:
  - Az  $Y_t^{(D)}$ -nél már a *rögtön következő* időpontban sincsen *semmilyen* hatása ennek
  - $Y_t^{(S)}$ -nél viszont az idősor *egész későbbi lefutását* befolyásolja, *csorbítatlanul*
- Bizonyos értelemben *ugyanazt* a trendet jelentik – gondoljunk a várható érték függvényre – de mégis teljesen eltérő *viselkedéssel*
- Megtestesítik a két iskolát:  $Y_t^{(D)}$  a lineáris trend a determinisztikus szemléletben (véletlen szerepe: csak az adott időszakra korlátozódik), az  $Y_t^{(S)}$  a lineáris trend sztochasztikus értelemben (véletlen szerepe: folyamatépítő)

**Hogy néznek ki?**

### Hogy néznek ki?



### Hogy néznek ki?



### Más elnevezések

- Főleg sztochasztikus folyamatos kontextusban az  $Y_t^{(S)}$ -et  $\alpha = 0$  esetén **véletlen bolyongásnak** (random walk, RW) is szokás nevezni
- Ráarakok egy bábut az origóra a számegyenesen, dobok egy véletlen számot ( $u_t$ ) és annyival odébb rakom, majd ezt ismétlem  $\rightarrow$  bolyongani fog a számegyenesen
- (Folytonos határa a Wiener-folyamat)
- Az  $\alpha \neq 0$  esetben pedig **eltolásos véletlen bolyongásról** (random walk with drift, RWD) szoktak beszélni

- Amennyiben az RW-t log-skálán vesszük, tehát  $\log Y_t = \log Y_{t-1} + u'_t$  a modellünk,  $Y_0 \neq 0$  mellett (eredeti skálára visszavetítve:  $Y_t = Y_{t-1} \cdot u_t = Y_0 \cdot \prod_{i=1}^t u_i$ ; nem a növekmények, hanem a hányadosok adott fae változók, nagyobb értékeknél nagyobb ingadozás) akkor **geometriai véletlen bolyongásról** szokás beszélni (pénzügyes szóhasználatban!)

## 5.3. ARMA-modellek

### 5.3.1. WN-folyamat

#### A fehérzaj (WN) folyamat

- A folyamat

$$u_t,$$

melyre  $\mathbb{E}(u_t) = 0$ ,  $\mathbb{D}^2(u_t) = \sigma^2$  és  $\text{cov}(u_t, u_s) = 0$  ( $t \neq s$ )

- Jele:  $\mathcal{WN}(0, \sigma_u^2)$
- Az eloszlásról nem mondtunk semmit
- Néha feltesszük, hogy nem csak korrelálatlan, de független is (általában nem ez az alapértelmezés, külön kell mondani); egyedül normális eloszlás feltevése esetén mindegy
- Zaj: logikus, ez valamilyen teljesen modellezhetetlen, struktúra nélküli folyamat
- De mitől fehér? ...optikai analógia!

A fény is felfogható egy idősornak, hiszen egy elektromágneses rezgés. Itt a spektrális elemzés nagyon jól érthető tartalommal bír, hiszen a fény frekvenciája egész egyszerűen a színe! (Ilyen értelemben a prizma, mely a ráejtett fényt „szétbontja” összetevő színeire, igazából nem más, mint egy spektrális elemzés fizikai implementációja!) Ismert, hogy a fehér fény az, amely azonosan tartalmaz minden színt; a fenti értelemben tehát a fehér fény spektruma egy vízszintes egyenes. A két dolog ott kapcsolódik össze, hogy belátható, hogy a fenti definiált idősor spektruma szintén egy vízszintes egyenes lesz – ilyen értelemben tehát a színek közül a fehér idősoros megfelelője.

### 5.3.2. MA-modellek

#### A mozgóátlagú (MA) modell

A  $q$ -ad rendű mozgóátlagú modell (modell, mivel most a sokaságban specifikáljuk):

$$Y_t = \alpha + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots + \theta_q u_{t-q},$$

ahol  $u_t$  hiba(folyamat), szokták itt úgy is hívni, hogy innováció, fehérzaj-folyamatnak tételezzük fel:  $u_t \sim \mathcal{WN}(0, \sigma_u^2)$ ;  $\alpha$  és  $\theta_i$ -k valós,  $\sigma_u^2$  pozitív valós konstans paraméterek

**MA(1)-folyamat: várhatóérték-függvény**

Közvetlenül a definíció alapján (a várhatóérték-képzést „ráeresztve” a definícióra):

$$\mu_t = \alpha + 0 + \theta_1 \cdot 0 = \alpha,$$

tehát  $\mu_t$  időfüggetlen

**MA(1)-folyamat: szórásnégyzet-függvény**

Közvetlenül a definíció alapján (a szórásnégyzet-képzést „ráeresztve” a definícióra):

$$\sigma_t^2 = 0 + \sigma_u^2 + \theta_1^2 \sigma_u^2 = \sigma_u^2 (1 + \theta_1^2)$$

tehát  $\sigma_t^2$  időfüggetlen (ez lesz  $\gamma_0$ )

**MA(1)-folyamat: autokovariancia-függvény**

Közvetlenül a definíció alapján (a kovariancia-képzést „ráeresztve” a definícióra):

$$\text{cov}(Y_t, Y_{t-1}) = \text{cov}(\alpha + u_t + \theta_1 u_{t-1}, \alpha + u_{t-1} + \theta_1 u_{t-2}) = \dots$$

összesen 9 tag, ebből azonban csak 1 nem-nulla (a többiben vagy konstans van, vagy különböző időpontokhoz tartozó  $u$ -k érintkeznek):

$$\dots = \text{cov}(\theta_1 u_{t-1}, u_{t-1}) = \theta_1 \sigma_u^2,$$

tehát ez időfüggetlen, jogos a  $\gamma_1$  jelölés

**MA(1)-folyamat: autokovariancia-függvény**

Közvetlenül a definíció alapján (a kovariancia-képzést „ráeresztve” a definícióra):

$$\text{cov}(Y_t, Y_{t-k}) = \text{cov}(\alpha + u_t + \theta_1 u_{t-1}, \alpha + u_{t-k} + \theta_1 u_{t-k-1}),$$

amiben immár – az előbbi logikát követve – mindegyik tag nulla ha  $k > 1$ .

Összefoglalva:

$$\gamma_k = \begin{cases} \sigma_u^2 (1 + \theta_1^2) & \text{ha } k=0 \\ \theta_1 \sigma_u^2 & \text{ha } k=1 \\ 0 & \text{ha } k>1 \end{cases}$$

**MA(1)-folyamat: stacionaritás**

Az előbbieket összerakva ( $\mu_t$  időfüggetlen,  $\sigma_t^2$  időfüggetlen,  $\gamma_k$  csak késleltetéstől függ) tehát kapjuk, hogy az MA(1) folyamat stacioner.

Mégpedig *mindig* az (értsd: paraméter-választástól függetlenül).

**MA(1)-folyamat: korrelogram**

- ACF:  $\rho_k = \frac{\gamma_k}{\gamma_0}$ ; eltűnik 1 késleltetés után
- PACF: belátható, hogy lecsengő (azaz  $\lim_{k \rightarrow \infty} \text{PACF}(k) = 0$ )



**MA(q)-folyamatok**

- $\mu_t = \alpha$  (ugyanazért)
- $\sigma_t^2 = \sigma_u^2 (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)$  (ugyanazért)
- ACF  $q$  késleltetés után eltűnő (ugyanazért)
- PACF lecsengő (ugyanúgy kiszámolható lenne), adott esetben bonyolultabb min-tázat szerint
- Mindig stacioner (paraméter-választástól függetlenül)!

**5.3.3. AR-modellek****Az autoregresszív (AR) modell**

A  $p$ -ed rendű autoregresszív modell (modell, mivel most a sokaságban specifikáljuk):

$$Y_t = \alpha + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + u_t,$$

ahol  $u_t$  hiba(folyamat), szokták itt úgy is hívni, hogy innováció, fehérzaj-folyamatnak tételezzük fel:  $u_t \sim \mathcal{WN}(0, \sigma_u^2)$ ;  $\alpha$  és  $\phi_i$ -k valós,  $\sigma_u^2$  pozitív valós konstans paraméterek

**Megjegyzések**

- Speciális esetek: ha  $p = 1$  és  $\phi_1 = 1$ , akkor RWD (ha ráadásul  $\alpha = 0$  akkor RW)
- Stacionaritás: ez – szemben az MA-folyamatokkal – nyilván nem lehet *mindig* stacioner, hiszen az RW sem az, de *néha* lehet az is (pl.  $p = 1$  és  $\phi_1 = 0$ ), a stacionaritásnak tehát itt valamilyen – paraméterekre vonatkozó – feltétele kell legyen
- Ennek vizsgálatát későbbre halasztjuk, és most azt mondjuk, hogy teljesültek ezek a feltételek

**AR(1) folyamat: várhatóérték-függvény**

Vegyük mindkét oldal várhatóértékét (feltettük a stacionaritást,  $\mathbb{E}(Y_t) \equiv \mu$ )

$$\mu = \alpha + \phi_1 \mu + 0,$$

mivel a várhatóérték lineáris, innen

$$\mu = \frac{\alpha}{1 - \phi_1}$$

( $\phi_1 \neq 1$  kell legyen: látni fogjuk, hogy ez tényleg fennáll, ha stacioner)

**AR(1) folyamat: szórásnégyzet-függvény**

Vegyük mindkét oldal szórásnégyzetét (feltettük a stacionaritást,  $\mathbb{D}^2(Y_t) \equiv \sigma^2$ )

$$\sigma^2 = \phi_1^2 \sigma^2 + \sigma_u^2,$$

kihasználva, hogy a három tag korrelálatlan, innen

$$\sigma^2 = \frac{\sigma_u^2}{1 - \phi_1^2}$$

( $|\phi_1| < 1$  kell legyen: látni fogjuk, hogy ez tényleg fennáll, ha stacioner)

**AR(1) folyamat: autokovariancia-függvény**

Kezdjük az 1 késleltetéssel (természetesen a stacionaritást most is feltételezzük):

$$\begin{aligned} \text{cov}(Y_t, Y_{t-1}) &= \text{cov}(\alpha + \phi_1 Y_{t-1} + u_t, Y_{t-1}) = \\ &= 0 + \phi_1 \text{cov}(Y_{t-1}, Y_{t-1}) + 0 = \phi_1 \sigma^2 = \phi_1 \frac{\sigma_u^2}{1 - \phi_1^2}, \end{aligned}$$

időfüggetlen; innen rekurzívan mehetünk tovább:

$$\text{cov}(Y_t, Y_{t-k}) = \text{cov}(\alpha + \phi_1 Y_{t-1} + u_t, Y_{t-k}) = \phi_1 \gamma_{k-1},$$

szintén időfüggetlen, ezekből tehát indukcióval kapjuk, hogy

$$\gamma_k = \phi_1^k \sigma^2 = \frac{\phi_1^k \sigma_u^2}{1 - \phi_1^2}$$

( $|\phi_1| < 1$  kell legyen: látni fogjuk, hogy ez tényleg fennáll, ha stacioner)

**AR(1) folyamat: autokorreláció és parciális autokorreláció-függvény**

Definíció alapján az autokovariancia-függvényből (mivel stacioner):

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi_1^k,$$

tehát az ACF *geometriailag lecsengő*

Külön kellene igazolni, de a mechanika alapján is elég nyilvánvaló, hogy

$$\text{PACF}(k) = \begin{cases} \rho_1 & \text{ha } k=1 \\ 0 & \text{ha } k>1 \end{cases}$$

Épp az MA(1) „fordítva”: a kettő korrelogramja egymás *duálisa*

**AR(1) folyamatok RWD-nél látott rekurzív visszafejtése**

$$\begin{aligned}
Y_t &= \alpha + \phi_1 Y_{t-1} + u_t = \alpha + \phi_1 (\alpha + \phi_1 Y_{t-2} + u_{t-1}) + u_t = \\
&= \alpha + \phi_1 \alpha + \phi_1^2 (\alpha + \phi_1 Y_{t-3} + u_{t-2}) + \phi_1 u_{t-1} + u_t = \dots
\end{aligned}$$

Ha feltételezzük, hogy „végtelenből jön” a folyamat (ekkor a kezdőérték mindegy lesz), akkor ez

$$\dots = \alpha \sum_{i=0}^{\infty} \phi_1^i + \sum_{i=0}^{\infty} \phi_1^i u_{t-i} = \frac{\alpha}{1 - \phi_1} + \sum_{i=0}^{\infty} \phi_1^i u_{t-i}$$

( $|\phi_1| < 1$  kell legyen: látni fogjuk, hogy ez tényleg fennáll, ha stacioner)

Mint egy MA-modell: ez az  $AR(1)$  modell  $MA(\infty)$ -reprezentációja

**AR(p) folyamatok**

- Stacionaritást egyelőre itt is feltételezzük
- Várhatóérték-függvény:  $\mu = \frac{\alpha}{1 - \phi_1 - \phi_2 - \dots - \phi_p}$
- Szórásnégyzet-függvény bonyolultabb (az autokovarianciák is megjelennek benne)
- Az ACF lecsengő (végtelenben 0-ba tart), de már bonyolultabb mintázat szerint is lehet
- PACF-ből az első  $p$  nem-nulla, a többi viszont már nulla
- Tehát az azonos rendű AR és MA folyamatok korrelogramja általánosságban is egymás duálisa
- Van  $MA(\infty)$ -reprezentációja

**5.3.4. ARMA-modellek****Az autoregresszív-mozgóátlagú (ARMA) modell**

A  $p, q$  rendű autoregresszív-mozgóátlagú modell (modell, mivel most a sokaságban specifikáljuk):

$$\begin{aligned}
Y_t &= \alpha + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \\
&+ u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots + \theta_q u_{t-q},
\end{aligned}$$

ahol  $u_t$  hiba(folyamat), szokták itt úgy is hívni, hogy innováció, fehérzaj-folyamatnak tételezzük fel:  $u_t \sim \mathcal{WN}(0, \sigma_u^2)$ ;  $\alpha$ ,  $\phi_i$ -k és  $\theta_i$ -k valós,  $\sigma_u^2$  pozitív valós konstans paraméterek.

### Tulajdonságok

- Stacionaritásnak feltétele van (ami csak az AR együtthatóktól függ)
- Ha fennáll, akkor mind az ACF, mind a PACF lecsengő (nem eltűnő), lehet, hogy bonyolultabb mintázat szerint
- Van  $MA(\infty)$ -reprezentációja

## 6 Késleltetési operátor és polinom, ARMA-folyamatok felírása késleltetési polinommal, az ARMA-folyamatok stacionaritása

### 6.1. Matematikai emlékeztető

#### 6.1.1. Algebra emlékeztető

**Változó, hatvány, polinom, polinom gyöke és inverze**

- Legyen  $x$  egy változó,  $x^k$  egy hatványa, ekkor  $\omega_0 + \omega_1 x + \omega_2 x^2 + \dots + \omega_k x^k = \omega(x)$  egy  $k$ -ad fokú, egyváltozós – polinom,  $\omega_0, \omega_1, \omega_2, \dots, \omega_k$  együtthatókkal
- (Az együtthatók és a változó értéke legegyszerűbb esetben valós számok, de ez nem szükségszerű)
- Megengedjük, hogy a fokszám végtelen is lehessen:  $\omega(x) = \sum_{i=0}^{\infty} \omega_i x^i$
- Polinom inverze:  $\omega^{-1}(x)$  olyan, hogy  $\omega^{-1}(x) \omega(x) = 1$
- Polinom gyöke: az  $\omega(x) = 0$  egyenlet megoldása
- Az algebra alaptétele: egy  $k$ -ad fokú valós polinomnak  $k$  darab – nem feltétlenül különböző – gyöke van, melyek vagy valósak, vagy ha komplexek, akkor konjugált párokban jönnek
- Az előbbi miatt egy polinom mindig felírható úgy – gyöktényezős alak – mint  $\omega(x) = \left(1 - \frac{1}{r_1}x\right) \left(1 - \frac{1}{r_2}x\right) \dots \left(1 - \frac{1}{r_k}x\right)$ , ahol  $r_i$  az  $i$ -edik gyök

**Polinom invertálása**

- Például  $1 - ax$  inverze  $1 + ax + (ax)^2 + (ax)^3 + \dots$  (egyesével egyeztetve az együtthatókat)
- Ez egy hatványsor, konvergál, ha  $|ax| < 1$

- Általános esethez induljunk ki a gyöktényezőző alakból:

$$\begin{aligned}\omega^{-1}(x) &= \left[ \left(1 - \frac{1}{r_1}x\right) \left(1 - \frac{1}{r_2}x\right) \cdots \left(1 - \frac{1}{r_k}x\right) \right]^{-1} = \\ &= \left(1 - \frac{1}{r_1}x\right)^{-1} \left(1 - \frac{1}{r_2}x\right)^{-1} \cdots \left(1 - \frac{1}{r_k}x\right)^{-1} = \\ &= \prod_{i=1}^k \left[ 1 + \frac{1}{r_i}x + \left(\frac{1}{r_i}x\right)^2 + \left(\frac{1}{r_i}x\right)^3 + \dots \right]\end{aligned}$$

- Ami konvergál, ha minden  $i$ -re  $\left|\frac{1}{r_i}x\right| < 1$ 
  - Ha  $|x| = 1$ , akkor a feltétel, hogy  $|r_i| > 1$ , azaz, hogy mindegyik gyök 1-nél nagyobb abszolútértékű legyen, más szóval, hogy a komplex egységkörön kívül legyen (ugye a gyökök komplexek is lehetnek)

## 6.2. Az ARMA-folyamatok mélyebb matematikája

### 6.2.1. A késleltetési operátor és a késleltetési polinom

#### A késleltetési operátor

- Legyen  $L$  valami, ami idősorból egy másik idősor csinál (ha  $y$  az eredeti idősor, akkor  $Ly$  jelöli az újat)
- ...mégpedig úgy, hogy  $(Ly)_t = y_{t-1}$
- Az egyszerűség kedvéért most fókuszáljunk a minta (realizálódott) idősorra, ne a sokasági szemléletre
- Fogjuk fel úgy, mint egy függvényt, ami az időkhöz értékeket rendel:  $y : \{1, 2, \dots, T\} \rightarrow \mathbb{R}$  és  $y : t \mapsto y_t$
- Az  $L$  tehát függvényből egy másik függvényt csinál: *operátor*

#### A késleltetési operátor (precízebben)

- A „függvény” itt igazából egy vektor ( $\mathbf{y} = (y_1 \ y_2 \ \cdots \ y_T)^T$ )
- (Ez rendben is van: egy  $n$  dimenziós valós vektor felfogható egy  $\{1, 2, \dots, n\} \rightarrow \mathbb{R}$  függvényként!)
- Ezek a függvények egy vektorteret alkotnak (függvény: a vektortér eleme, skalárral szorzás: pontonként szorzás, összeadás: pontonkénti összeadás), ezt szokás függvénytérnek nevezni

- A fenti esetben ez megfelel az  $n$ -dimenziós valós vektorokkal végzett szokásos műveleteknek
- Az operátor – úgy általában – igazából két vektortér közti leképezés
- A függvényterez értelmezés miatt mondhattuk azt, hogy az „operátor az, ami függvényből másik függvényt csinál”!

### A késleltetési operátor (precízebben)

- Ha a vektoros felfogást, és azon belül is az  $n$ -dimenziós valós vektoroknak való megfeleltetést vesszük, akkor minden operátor reprezentálható mátrixszal (hiszen a mátrix az, ami vektorból vektort csinál!)
- Ez alól a késleltetési operátor sem kivétel, például:

$$\underbrace{\begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}}_{\mathbf{L}} \cdot \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{pmatrix}}_{\mathbf{y}} = \begin{pmatrix} 0 \\ y_2 \\ y_3 \\ y_4 \end{pmatrix},$$

- (Azért, hogy ne változzon az idősor hossza, az új első eleme legyen fixen 0)

### A késleltetési operátor hatványai

- Micsoda  $L^2$ ?
- Könnyen értelmezhető:  $L(Ly_t) = Ly_{t-1} = y_{t-2}$
- Röviden:  $L^2 y_t = y_{t-2}$
- Megfeleltethető a mátrixoknak? Igen! Az  $\mathbf{L}$  mátrix négyzete épp a kettővel késleltetést valósítja meg, azaz  $\mathbf{L}^2 = L^2$
- Szorozzuk össze, és ellenőrizzük le, hogy ez csakugyan teljesül!
- Hasonlóan  $L^k y_t = y_{t-k}$ , tehát ez a  $k$ -val késleltető operátor lesz
- (Ideértve azt is, hogy például  $L^{-1} y_t = y_{t+1}$ , „siettető operátor”)

### A késleltetési polinom

- A késleltetett idősorokat kombinálhatjuk is, például  $2y_t + 3y_{t-1} - 4y_{t-2} = 2y_t + 3Ly_t - 4L^2 y_t = \dots$
- Most jön az érdekes rész: ez átírható mint

$$\dots = (2 + 3L - 4L^2) y_t$$

- Ami fontos, hogy ez nem „szintaktikai manipuláció”, az előbbi mátrixok nagyon is mutatják ennek a realitását:  $2\mathbf{I} + 3\mathbf{L} - 4\mathbf{L}^2$  épp az a mátrix, amivel rászorozva az idősorra pont  $2y_t + 3y_{t-1} - 4y_{t-2}$ -t kapjuk!
- Ennek általánosítása a késleltetési polinom:

$$\omega(L) = \omega_0 + \omega_1 L + \omega_2 L^2 + \dots + \omega_k L^k,$$

azaz az operátorokból is ugyanúgy gyárthatunk polinomot – az előbb definiált hatványaik segítségével – mint mondjuk valós ismeretlenekből

- Ezzel  $\omega(L) y_t = \omega_0 y_t + \omega_1 y_{t-1} + \omega_2 y_{t-2} + \dots + \omega_k y_{t-k}$
- Természetesen  $\omega(L)$  maga is egy operátor

### A késleltetési polinom használatának előnye

Számos – egyébként bonyolult – művelet elvégezhető, mint (jól ismert) manipuláció polinomokkal: összeszorozhatóak, invertálhatóak stb.!

### 6.2.2. ARMA-folyamatok reprezentációja késleltetési polinomokkal

#### ARMA-folyamatok felírása késleltetési polinomokkal

- Emlékeztetőül:

$$Y_t = \alpha + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots + \theta_q u_{t-q}$$

- Kicsit átrendezve:

$$Y_t - \phi_1 Y_{t-1} - \phi_2 Y_{t-2} - \dots - \phi_p Y_{t-p} = \alpha + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots + \theta_q u_{t-q}$$

#### ARMA-folyamatok felírása késleltetési polinomokkal

- Az előbbiek alapján ez átírható mint

$$Y_t - \phi_1 L Y_t - \phi_2 L^2 Y_t - \dots - \phi_p L^p Y_t = \alpha + u_t + \theta_1 L u_t + \theta_2 L^2 u_t + \dots + \theta_q L^q u_t$$

- Azaz:

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) Y_t = \alpha + (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q) u_t$$

- Vezessünk be két késleltetési polinomot:  $\phi(x) = 1 - \phi_1 x - \phi_2 x^2 - \dots - \phi_p x^p$  és  $\theta(x) = 1 + \theta_1 x + \theta_2 x^2 + \dots + \theta_q x^q$
- Ezekkel az előbbi egész egyszerűen

$$\phi(L) Y_t = \alpha + \theta(L) u_t$$



### ARMA-folyamatok vizsgálata polinomiális reprezentációval: stacionaritás

- Az előbbi egyenletet átalakítva:

$$Y_t = \phi^{-1}(L) \alpha + \phi^{-1}(L) \theta(L) u_t$$

- Legalábbis, ha  $\phi(L)$  invertálható!
- Ehhez az kell, hogy a gyökei a polinomnak az egységkörön kívül legyenek
  - Mert az  $L$  úgy viselkedik, mint az 1 abszolútértékű szám (1 az operátornormája)
- Lényegében azt jelenti, hogy létezik  $MA(\infty)$ -reprezentáció
- És most jön a lényeg: ez épp a *stacionaritás* feltétele!
- (Persze ez bizonyítást igényel)

### ARMA-folyamatok vizsgálata polinomiális reprezentációval: invertálhatóság

- Ha viszont  $\theta(L)$  gyökei vannak az egységkörön kívül, akkor az egész  $AR(\infty)$ -folyamatként reprezentálható
- Ilyenkor azt mondjuk, hogy a folyamat *invertálható*
- Lényegében azt jelenti, hogy az  $u_t$  is felírható  $Y$  aktuális és múltbeli értékeivel (nem csak fordítva)



## 7 A stacionaritás tesztelése


### 7.1. A stacionaritás tesztelése

#### 7.1.1. A stacionaritás teszteléséről általában

##### A tesztelés lehetőségei


- Egy módszerről már volt szó (grafikus eljárás), de ez igen szubjektív
- Most kiegészítjük két újjal, a második, a korrelogram szemrevételezése még mindig inkább csak heurisztikus...
- ...de a harmadik, a statisztikai próbák alkalmazása már objektív (noha ez nem azt jelenti, hogy tökéletes!)

##### Grafikus módszer



##### Grafikus módszer


## 7 A stacionaritás tesztelése



### A grafikus módszer határai

- A (gyenge) stacionaritás három feltételéből igazából csak kettő vizsgálható egyáltalán „ránézésre”
- Nem állandó várható érték, nem állandó szórás (akár csak átmenetileg is!)
- A mintavételi ingadozás figyelembevételére nincsen formális módszer, nehéz megítélni (különösen ha nem túl nagy a mintanagyság)
- Szubjektív

### Korrelogram szemrevételezése



**Korrelogram szemrevételezése – miért működik?**

- Azt kell nézni, hogy az ACF nagyon nem lecsengő-e
- (Figyelem: a „nagyon nem lecsengő” nem azt jelenti, hogy nem igaz az, hogy nullába tart, hanem azt, hogy az 1-től is alig szakad el!)
- Miért van ez így?
- Intuitív indoklás, gondoljunk arra, ha trendje van az idősornak
- (A végigtolt ablaknak mindkét vége vagy az átlag alatt, vagy az átlag felett lesz az esetek nagy részében; ez csak lassan oldódik az ablak szélességének növekedtével)

**Statisztikai tesztek**

- Ez az igazán objektív módszer, kapunk egy  $p$ -értéket, ebben nincsen szubjektív tényező
- A gyakorlatban legelterjedtebb módszerek valójában inkább azt ellenőrzik, hogy van-e ún. egységgyök a folyamat (nem általában azt, hogy „nem stacioner”), ld. mindjárt
- Például Dickey-Fuller teszt (DF), kiterjesztett Dickey-Fuller teszt (ADF, augmented DF)
- Lásd kicsit később

**7.1.2. Egységgyökök****Az egységgyökök fogalma**

- Láttuk, hogy egy ARMA-folyamat akkor stacioner, ha az AR-rész polinomjának,  $\phi(L)$ -nek az összes gyöke az egységkörön kívül van
- Pontosítsuk ezt az állítást:
  1. Ha az összes gyök az egységkörön kívül van, akkor a folyamat stacioner (eltolásinvariánsak a momentumok, egyedi impulzusok hatása lecsengő)
  2. Ha akár csak egyetlen gyök is az egységkörön belül van, akkor a folyamat **explozív** (momentumok elmennek a végtelenbe – esetleg oszcillálva –, az egyedi impulzusok hatása felerősödő)
  3. Ha egységkörön *belül* nincs gyök, de az egységkörön *van* – egy vagy több – akkor ugyan nem stacioner, de egy furcsa helyzet áll elő
- (Gondoljunk mindezeket végig az  $Y_t = \alpha + \phi_1 Y_{t-1} + u_t$  példáján!)

- Az említett 3. helyzet határeset: az egyedi impulzusok hatása sem nem lecsengő, sem nem felerősödő, a momentumok felemásan viselkednek (pl. variancia elszáll, de várható érték állandó)
- Ezt hívjuk **egységgyök-folyamatnak** (azt is mondjuk, hogy a folyamatban egységgyök van)

#### Az egységgyök és a differenciastacionaritás kapcsolata

- Ha  $\phi(x)$ -nek egy darab 1 értékű gyöke van (a többi nagyobb), akkor úgy is írható mint  $\phi(x) = \tilde{\phi}(x)(1-x)$ , ahol  $\tilde{\phi}(x)$ -nek már minden gyöke 1-nél nagyobb
- Igen ám, de ezzel a  $\phi(L)Y_t = \alpha + \theta(L)u_t$  úgy is írható, mint

$$\tilde{\phi}(L)(1-L)Y_t = \alpha + \theta(L)u_t,$$

azaz

$$\tilde{\phi}(L)\Delta Y_t = \alpha + \theta(L)u_t$$

- Vagyis ilyenkor az idősor differenciázottjára adtunk egy ARMA-modellt!
- Egész pontosan ARMA(p-1,q)-t, hiszen az AR-polinomja ( $\tilde{\phi}(L)$ ) eggyel kisebb fokszámú

#### Az egységgyök és a differenciastacionaritás kapcsolata

- Azaz: ha – egyszeres – egységgyök van egy ARMA folyamatban, az épp azt jelenti, hogy differenciastacioner, mégpedig  $I(1)$  lesz, mert a differenciázottja stacioner ARMA lesz
- Ez egy fontos magyarázat arra, hogy miért találjuk azt, hogy a differenciázás sokszor segít: épp az egységgyököt tünteti el!
- Hasonlóan, ha az 1  $d$ -szeres gyök, akkor a  $d$ -szer differenciázott folyamat lesz stacioner, tehát az eredeti folyamat  $I(d)$  volt

#### Egységgyök-tesztelés: DF-teszt

- Tekintsünk először egy AR(1)-modellt:  $Y_t = \alpha + \phi_1 Y_{t-1} + u_t$  a szokásos feltevésekkel
- Az egyértelmű, hogy  $H_0 : \phi_1 = 1$ , klasszikusan legtöbbször a  $H_1 : \phi_1 < 1$  alternatívával szemben vizsgálódunk
- (Mert: az explozív idősorokat teljesen kizárjuk a vizsgálódásunk köréből)
- Rögtön érthetővé válik, amit arról mondtunk, hogy ez nem „stacionaritási teszt”, hanem egységgyök teszt (bár ebben az esetben a kettő *majdnem* ugyanaz, az egyetlen különbség az explozivitás kizárása)

- A teszteléshez térjünk át a differenciákra:

$$\Delta Y_t = \alpha + \delta_1 Y_{t-1} + u_t,$$

ahol  $\delta_1 = \phi_1 - 1$

- Ennek megfelelően itt a tesztünk:  $H_0 : \delta_1 = 0$  vs  $H_1 : \delta_1 < 0$

### Egységgyök-tesztelés: DF-teszt

- Egyszerűen eresszünk rá egy  $t$ -próbát?
- Nem jó ötlet, mert  $\delta_1$   $t$ -hányadosának nem  $t$ -eloszlása lesz
  - Klasszikusan azzal indokoljuk a  $t$ -eloszlást, hogy ha nagy a mintánk, akkor ez (aszimptotikusan) eloszlási feltevésektől függetlenül teljesül, a centrális határeloszlás tétele miatt
  - Csakhogy itt a CLT nem fog érvényesülni, mert  $Y_{t-1}$  integrált idősor (gondoljunk bele, a varianciája minden határon túl nőni fog, ha a mintanagyság egyre nagyobb!)
- David Dickey és Wayne Fuller 1979-ben nagy számú szimulációval tisztázta, hogy
  - legalábbis aszimptotikusan – milyen eloszlása van akkor ennek, ha nem  $t$ , ezt hívjuk DF-eloszlásnak
- Ez alapján (vagy legalábbis a kitáblázott kritikus értékek alapján) már végezhető teszt: DF-teszt

### Egységgyök-tesztelés: DF-teszt

- A gyakorlatban három módon szoktuk alkalmazni (más a DF-eloszlás mindegyikéhez):
  1.  $\alpha = 0$  (konstans és trend nélkül): sztochasztikusan sem lehet benne trend (nulla körül kell ingadozzon a differenciázott)
  2.  $\alpha$ -ra nincs megkötés (konstanssal, de trend nélkül): sztochasztikusan lehet benne trend (ez a tipikusabb)
  3. Determinisztikus – lineáris – trend kiszűrése után az előbbi (konstanssal és trenddel): a trendszűrt idősort teszteljük, azaz itt a trend-stacionaritást, és nem a stacionaritást tudjuk vizsgálni (azzal ekvivalens, hogy az  $Y_t = \alpha_0 + \alpha_1 t + \phi_1 Y_{t-1} + u_t$ -ből indulunk ki)
- (Esetleg másféle trend, vagy szezonális dummy-k is használhatóak)
- Hátrányok: sajnos kicsi lehet ez ereje ha a  $\phi_1$  kisebb mint 1, de csak kevéssel
- Hátrányok: csak akkor valid, ha az eredeti idősorra *tényleg* igaz volt az AR(1)-specifikáció (dinamikailag helyesen specifikált a modell, tehát *tényleg* ilyen alakú, és *tényleg* elég 1 késleltetés)

**Egységgyök-tesztelés: ADF-teszt**

- Próbáljuk kijavítani az előbbi hátrányt!
- Belátható, hogy ez úgy érhető el, ha áttérünk a

$$\Delta Y_t = \alpha + \delta_1 Y_{t-1} + \gamma_1 \Delta Y_{t-1} + \gamma_2 \Delta Y_{t-2} + \dots + \gamma_p \Delta Y_{t-p} + u_t$$

modellre, ami akkor is működni fog, ha az eredeti folyamat magasabb – de  $p$ -nél nem nagyobb – rendű AR-folyamatot követ

- A rend megválasztása külön kérdés; általában információs kritériummal, vagy  $\gamma$ -k tesztelésével végzik (azoknak szerencsére szokásos, azaz  $t$  és – együttesen –  $F$  eloszlásaik vannak, legalábbis aszimptotikusan)



## 8 A nemstacionaritás kezelése: stacionarizálás, trend- és differenciastacioner idősorok, differenciázás, ARIMA-folyamat

### 8.1. Stacionarizálás

#### A stacionarizálás szükségessége

- Mi alapvetően stacioner idősorokat szeretnénk majd modellezni (például olyan ARMA-val akarunk idősört modellezni, ami stacioner)
- De: a legtöbb közgazdasági idősor *nem* stacioner!
- Mit csináljunk most?
- Olyan „visszacsinálható” (invertálható) transzformációt alkalmazunk, ami a nem-stacioner idősorból stacionert csinál
- Azon elvégezzük a modellezést (és ha kell, a transzformáció inverzével visszatérünk az eredeti idősor nagyságrendjébe)
- Két módszert fogunk látni
- Ez nem univerzális: nem arról van szó, hogy valamelyiknek matematikai szükség-szerűség, hogy stacionarizálnia kell minden idősört, egész egyszerűen azért nézzük meg ezeket, mert a gyakorlatban sokszor beváltak

#### Determinisztikus trend szűrése

- Az első módszer a determinisztikus trend szűrése: az idősorra ráillesztünk egy analitikus trendet majd kivonjuk belőle, ezt jelenti a „szűrés”
- Például (lineáris trend szűrése):

$$Y_t = \alpha + \beta t + u_t$$

modell alapján megbecsüljük  $\alpha$  és  $\beta$  értékét (OLS- vagy ML-elven), majd áttérünk a – reményeink szerint stacioner –

$$Y'_t = Y_t - (\hat{\alpha} + \hat{\beta}t)$$

idősorra

- Ilyen értelemben mondjuk, hogy kiszűrtünk belőle egy determinisztikus trendet
- (Lényegében az egyenes illesztése utáni reziduumokra térünk át)
- Visszatérés: a trend hozzáadása

### Determinisztikus trend szűrése

- Ha ezzel a transzformációval az idősor stacionarizálható (tehát  $Y'_t$  már stacioner), akkor azt mondjuk, hogy az eredeti  $Y_t$  idősor **trendstacioner folyamat** (TSP, trend stationary process) volt
- Természetesen nem muszáj egyszerű lineáris trendet szűzni, illeszthetünk kvadrátikus trendet ( $\alpha + \beta t + \gamma t^2$ ), exponenciális trendet ( $\alpha e^{\beta t}$ ), szezonalitást, bármit, a lényeg, hogy egy előre megadott determinisztikus függvényforma legyen
- (A dolog ugyanis azért fog működni, mert amit illesztünk, annak a paramétereit szigorúan exogének)
- Vegyük észre, hogy ez filozófiájában a korábban látott „determinisztikus trend” fogalmához illeszkedik: ha egy idősorban trend van, de az determinisztikus ( $Y_t^{(D)} = \alpha t + u_t$ ), akkor épp ez a módszer fogja stacionarizálni

### Differenciázás

- Ha az idősorban viszont sztochasztikus trend van ( $Y_t^{(S)} = Y_{t-1}^{(S)} + \alpha + u_t$ ), akkor egy másik, de pofonegyszerű transzformációval stacionarizálhatjuk:

$$Y'_t = Y_t - Y_{t-1}$$

- Hiszen ha az idősor valóban az előbbi modell követi, akkor a fenti transzformáció eredménye

$$Y'_t = \alpha + u_t$$

lesz, ami feltevéseink szerint tényleg stacioner

- Ezt a transzformációt úgy hívjuk, hogy az idősor **differenciázása**, jele  $\Delta$ , ez is egy *operátor*:

$$\Delta Y_t = Y_t - Y_{t-1} = Y_t - L Y_t = (1 - L) Y_t,$$

tehát  $\Delta = 1 - L$

**Differenciázás**

- Ha ezzel a transzformációval az idősor stacionarizálható (tehát  $Y'_t$  már stacioner), akkor azt mondjuk, hogy az eredeti  $Y_t$  idősor **differenciastacioner folyamat** (DSP, difference stationary process) volt
- Visszatérés: felkumulálás (kezdőértékre szükség lesz):

$$Y_t = Y_0 + \sum_{i=1}^t \Delta Y_i$$

- (Itt már ráismerhetünk, hogy a differenciázás igazából nem más, mint a *diszkrét deriválás*: ha diszkrét halmazon vagyunk, akkor a  $\lim_{\Delta t \rightarrow 0}$  azt jelenti, hogy  $\Delta t = 1$ , azaz, hogy két egymást követő időpont különbségét nézzük, és ilyenkor persze le sem kell osztani  $\Delta t$ -vel)
- Emiatt azt is mondjuk, hogy a folyamat elsőrendben integrált, jelben  $I(1)$

**Differenciázás**

- A differenciázás lineáris trendet tüntet el (ha az sztochasztikus értelmű)
- Mi van, ha kvadratikus trendet kell eltüntetnünk?
- Ugyanúgy, ahogy az  $ax + b$  függvényt a deriválás teszi konstanssá, az  $ax^2 + bx + c$ -t pedig a kétszeri deriválás, ilyenkor a *kétszeri differenciázás* (*másodrendű differenciázás*) lesz a megoldás:

$$\begin{aligned} \Delta(\Delta Y_t) &= \Delta(Y_t - Y_{t-1}) = (Y_t - Y_{t-1}) - (Y_{t-1} - Y_{t-2}) = \\ &= (Y_t - 2Y_{t-1} + Y_{t-2}) \end{aligned}$$

- A jele  $\Delta^2$
- Az előbbi eredmény nem meglepő, hiszen

$$\Delta^2 = (1 - L)^2 = 1 - 2L + L^2$$

- Ha egy folyamat így stacionarizálható, akkor azt mondjuk, hogy másodrendben integrált, jelben  $I(2)$

**Differenciázás**

- Természetesen a dolog általánosítható:  $\Delta^d$  a  $d$ -ed rendbeli ( $d$ -szeri) differenciázás,  $\Delta^d = (1 - L)^d$

- Ha egy idősor nem stacioner, az első differenciázottja sem az, a második differenciázottja sem az, ..., de a  $d$ -szeri differenciázottja már igen (tehát  $d$  a legkisebb egész szám, hogy az annyiszoros differenciázott már stacioner), akkor azt mondjuk, hogy az idősor  $d$ -ed rendben integrált, jelben  $I(d)$
- (Ennek megfelelően a stacioner idősor nulladrendben integrált, jelben  $I(0)$ )
- Ez a tipikusabb a közgazdasági gyakorlatban
- Olyannyira, hogy ennek ARMA-val való kombinációjára külön elnevezés van: ha egy  $d$ -ed rendben integrált idősor  $d$ -szeres differenciázottját modellezzük ARMA( $p, q$ )-val, akkor azt is mondhatjuk, hogy az eredeti idősort **ARIMA**( $p, d, q$ )-val modelleztük

## 9 Box-Jenkins eljárás, előrejelzés készítése

### 9.1. Box-Jenkins eljárás

#### A Box-Jenkins eljárás lényege

- Az alapgondolat: az idősorokat – stationer – ARIMA( $p,d,q$ )-modellel írjuk le...
- ...a paramétereket úgy megválasztva, hogy a modellfeltevések teljesüljenek
- A nevét két fő proponenséről – George Box és Gwilym Jenkins – kapta, akiknek az 1970-es könyve (Time Series Analysis: Forecasting and Control) nagyon sokat tett a módszer széles körben történő megismertetéséért és elterjesztéséért

#### A Box-Jenkins eljárás lépései

1. A  $d$  meghatározása: már láttuk a módszereit (lényegében stacionarizálás/stacionaritás tesztelése)
2. A  $p$  és  $q$  rendek behatárolása: azért nem „meghatározása”, mert jellemzően nem egyértelmű, többféle lehetőséggel is próbálkozni kell (de általában igyekszünk kicsin tartani ezeket), egyedül a korrelogram segíthet, ha szemrevételezzük és összevetjük azzal, hogy az elméleti korrelogramok hogyan néznek ki (de ez általában csak tiszta AR vagy MA modelleknél működőképes)
3. Modell becslése: technikai lépés, most nem foglalkozunk vele
4. Modelldiagnosztika: reziduumok vizsgálata, minimum autokorrelálatlanságra (korrelogram, Ljung-Box teszt, Breusch-Godfrey teszt), esetleg normalitásra
5. Modellminősítés: jellemzően információs kritériumokat (AIC, BIC (SBC), HQC) használunk

#### A Box-Jenkins eljárás lépései

- A  $p$  és  $q$  behatárolásához tehát lényegében egy kétlépcsős megoldást alkalmazunk:
  - Szűrés: ami diagnosztikailag nem megfelelő, azok a modellek szóba sem jöhetnek, kidobjuk őket a jelöltek listájáról (ez tehát a modelldiagnosztika alapján megy)

- Sorbarakás: ha nem egyetlen modell marad fenn, akkor azokat sorbarakjuk, és a – valamely metrika szerinti – legjobbat választjuk (ez tehát a modellminősítés alapján megy)
- Az így kapott modellt pedig felhasználjuk
- Itt jellemzően a felhasználás nem elemzést, hanem előrejelzést jelent

## 9.2. Előrejelzés készítése

### Az előrejelzés alapelve

- Természetesen itt is feltételes várható értékkel predikálunk, azaz az előrejelzéshez behelyettesítünk minden ismert változót (ARMA-modellnél ez a folyamat múltbeli értékeit, és a múltbeli hibákat jelenti), és a tárgyidőszaki hibatagot nullának vesszük
- Ilyen módon ARMA-modellben csak egyetlen időszakra tudunk előrejelezni; ennek neve **statikus előrejelzés**
- Statikus előrejelzésben csak realizálódott értékre támaszkodunk (a tárgyidőszaki hibától eltekintve, természetesen)
- Ha több időszakra kell előrejeleznünk, akkor
  - a későbbi hibákat mind nullának kell vennünk (nem csak a tárgyidőszakit)
  - a múltbeli értékek sem lesznek mind realizálódottak – ilyenkor a korábbi előrejelzésre támaszkodunk
- Ezt hívjuk **dinamikus előrejelzésnek**

### Előrejelzések készítése

- Mindez összefoglalva azt jelenti, hogy
  - a hibatag helyébe a reziduumot írjuk, ha mintán belül vagyunk, 0-t, ha azon kívül
  - a múltbeli érték helyébe a realizálódott értékét írjuk, ha mintán belül vagyunk, a becsült értéket, ha azon kívül
- Az ARMA-folyamat tulajdonságaiból adódik, hogy nagyon messzire előremenve az előrejelzéssel a folyamat várható értékéhez fogunk konvergálni
- ARIMA-modellezésnél utolsó lépésben még vissza kell csinálni a differenciázást (kumulálni kell)

**Az előrejelzés pontosságának a mérése**

A két legtipikusabb mutató:

- Átlagos négyzetes hiba:  $MSE = \frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2$
- Átlagos abszolút relatív hiba:  $MAPE = \frac{1}{T} \sum_{t=1}^T \frac{|y_t - \hat{y}_t|}{y_t}$





# 10 Idősorok regressziója

## 10.1. Exogén változós idősormodellek

### 10.1.1. Alapgondolatok, statikus regresszió

#### Idősorok regressziójának alapgondolata

- Az idősorunkat *más* idősor(ok)kal akarjuk magyarázni
- Lényegében tehát *ki akarjuk regresszálni* az idősorunkat (mint eredményváltozót), más idősorokkal (mint magyarázó változókkal)
- Bizonyos értelemben az eddigi AR-modellek is ilyenek voltak, csak a „más idősor” ugyanannak a késleltetettjeit jelentette
- Most viszont megengedjük, hogy tényleg eltérő idősorok (vagy azok késleltetettjei!) is belépjenek magyarázó változóként
- A fő kérdésünk az lesz, hogy e modelleknek milyen feltételeket kell teljesíteniük, hogy jó tulajdonsággal becsülhetőek legyenek a paramétereik
- És persze szokásosan az ökonometriai modellek két felhasználása: elemzés és előrejelzés

#### Statikus regresszió

- A legegyszerűbb idősoros regressziós modell:

$$y_t = \beta_0 + \beta_1 z_t + u_t,$$

ahol  $y_t$  és  $z_t$  tehát két idősor *ugyanazon* időpontbeli megfigyelései

- Például: statikus Phillips-görbe (infláció vs. munkanélküliség)
- Az  $u_t$  hibatag és tulajdonságai lesznek majd vizsgálódásunk fókuszában, ami a modellfeltevéseket illeti
- Legegyszerűbb eset, ha  $z_t$  valami „teljesen más”,  $u_t$ -től külső információ (ezt majd pontosítjuk), úgy fogjuk mondani, hogy **exogén változó**
- Természetesen lehet több exogén változó is:

$$y_t = \alpha + \beta_1 z_{t1} + \beta_2 z_{t2} + \dots + \beta_k z_{tk} + u_t$$

### Statikus regresszió

- $\beta_i$  jelentése: ha az  $i$ -edik idősor értéke egy adott időszakban egy egységgel megnő (minden mászt változatlanul tartva), akkor modellünk szerint várhatóan hány egységgel lesz nagyobb az eredményváltozó *ugyanazon* időszakban
- Azért hívjuk statikusnak, mert ugyanazon időszaki változásokat kapcsol össze, tehát nincs időszakok közötti hatás
- (A dinamika szó általában is időben kiterjedten lezajló dolgokra utal)

### 10.1.2. Dinamikus regressziók

#### A dinamika szükségessége

- Rengeteg helyzetben a statikusság irreális
- Nem várható, hogy egy beruházás rögtön *ugyanabban* az időpontban befolyásolja a kibocsátást, hogy egy felvilágosítókampány *azonnal* lecsökkenti a megbetegedések számát, hogy egy szociálpolitikai intézkedés *rögtön* megváltoztatja a jövedelmi viszonyokat stb.
- A legtöbb társadalmi-gazdasági jelenség csak időben elnyújtva, késleltetéssel hat, több időszakon keresztül fejti ki a hatását
- Ezért szükséges a dinamika beépítése is a regressziós modelljeinkbe

#### Osztott késleltetésű modellek

- A legegyszerűbb dinamikus modell: legyen most csak egyetlen magyarázó változónk, csak épp

$$y_t = \beta_0 + \delta_0 z_t + \delta_1 z_{t-1} + \delta_2 z_{t-2} + \dots + \delta_p z_{t-p} + u_t$$

- Az idősor tárgyidőszaki értékére a korábbi  $z$ -k is hatást gyakorolnak...
- ... avagy – fordítva elmondva ugyanazt – a  $z$  mostani változásai a jövőben fognak kihatni  $y$ -ra
- $\beta_i$ : ha  $z$  most megváltozik, akkor  $i$  időszakkal később ez hogyan hat  $y$ -ra
- Amennyiben véges sok korábbi  $z$  hat  $y$ -ra (később fogjuk látni hogyan hathat végtelen sok korábbi), akkor **véges osztott késleltetésű** modellről (FDL, finite distributed lag) beszélünk

**Az FDL-modell**

- Ha  $z$  konstans, majd egy időszakra felugrik eggyel nagyobbra, majd után visszaáll a konstans szintre, akkor a tárgyidőszaki  $y$   $\beta_0$ -al lesz nagyobb mint az állandósult szintje, az eggyel később  $y$   $\beta_1$ -gyel, ..., a  $p$ -vel későbbi időszakban  $\beta_p$ -val, és a  $p$  utáni időszakokra már nem hat ez a módosulás
- Ezeket hívjuk **rövid távú hatásmultiplikátornak**, értéke tehát az  $i$ -edik időszakra épp  $\beta_i$
- Éppen ezért szokás kiplottolni  $\beta_i$ -t a  $i$ -vel szemben
- A másik tipikus értelmezési keret, hogy  $z$  egy adott időszakban felugrik eggyel és *úgy is marad*, kérdés, hogy hosszú távon mi történik  $y$ -nal
- Ugyanabban az időszakban  $\beta_0$ -al nő meg, a következőben  $\beta_0 + \beta_1$ -gyel és így tovább
- Ezt hívjuk **hosszú távú hatásmultiplikátornak**, értéke tehát  $\sum_{i=0}^p \beta_i$

**FDL-modell strukturálatlan becslése**

- Ha a fenti módon egyszerűen megbecsüljük  $\beta$ -kat, akkor **strukturálatlan becslésről** beszélünk (mert semmit nem tettünk fel a  $\beta$ -k értékeiről)
- A probléma ezzel, hogy nagyon sok esetben egy idősor egymást követő értékei nagyon korreláltak  $\rightarrow$  a fenti modellben rendkívül erős multikollinearitás lesz, a  $\beta$ -kat csak nagyon bizonytalanul (hatalmas CI-vel) tudjuk csak becsülni
- (*Együttesen* vizsgálhatóak, például  $F$ -teszttel, vagy a hosszú távú hatásmultiplikátort is jól meg tudjuk becsülni, csak külön-külön nem)

**FDL-modell struktrált becslése, Almon-lag**

- Éppen ezért gyakori, hogy nem teljesen szabadon becsüljük  $\beta_i$ -ket, hanem feltételezünk valamilyen struktúrát
- Lényegében: átcseréljük az eredeti paramétereket kisebb számú, kevésbé multikollineáris paraméterekre
- (Persze ennek az az ára, hogy a struktúrát el kell találnunk, az ugyanis nem az adatokból jön, hanem mi mondjuk meg kívülről)
- Az egyik népszerű választás az **Almon késleltetési struktúra**, amikor azt feltételezzük fel, hogy a  $\beta_i$ -k az  $i$ -ben polinomiálisak:

$$\beta_i = \sum_{j=0}^n w_j i^j,$$

ahol  $n$  tipikusan kicsi (pl. 2-3)

- Akármennyi is  $p$ , nekünk csak  $n$  darab – általában már nem túl multikollineáris – paramétert kell becsülnünk
- De még egyszer: fontos, hogy  $\beta_i$  tényleg kvadratikusan (/kübös/stb.) legyen  $i$ -ben

### FDL-modell strukturált becslése, Koyck-lag (GDL)

- Egy másik népszerű választás, hogy  $\beta_i$  geometriailag lecsengő  $i$ -ben:

$$\beta_i = \beta_0 \rho^i,$$

ahol természetesen  $|\rho| < 1$

- (Azt is mondhattuk volna, hogy  $\beta_i = \rho \beta_{i-1}$ )
- Ezt hívják **Koyck késleltetési struktúrának**
- Ami nagyon érdekes, hogy ehhez igazából az sem kell, hogy csak véges sok késleltetés lépjen be a modellbe!
- Nyugodtan lehet az a modellünk, hogy

$$y_t = \beta_0 + \delta_0 z_t + \delta_1 z_{t-1} + \delta_2 z_{t-2} + \dots + u_t,$$

*nem* lesz végtelen sok becsülendő paraméterünk, hiszen a DL részhez tartozó paraméterek száma *mindenképp* 2 ( $\beta_0$  és  $\rho$ )

- Tehát értelmesen megbecsülhető a fenti specifikáció is, mintegy végtelen osztott késleltetésű modellként, a neve **geometriai osztott késleltetű** modell (GDL, geometric distributed lag)

### A GDL-modell értelmezése

- A rövid távú hatásmultiplikátor tehát  $\beta_i = \beta_0 \rho^i$
- A hosszú távú hatásmultiplikátor izgalmasabb:

$$\sum_{i=0}^{\infty} \beta_i = \sum_{i=0}^{\infty} \beta_0 \rho^i = \beta_0 \sum_{i=0}^{\infty} \rho^i = \frac{\beta_0}{1 - \rho}$$

### 10.1.3. Idősoros regressziók általános modellje

#### Az eddigiek kombinációja

- Az eddigiek természetesen kombinálhatóak is: lehet benne *több*  $z$  is, akár késleltetve
- Természetesen lehet vegyesen is (bizonyosak késleltetés nélkül, mások késleltetéssel, a rend sem kell, hogy azonos legyen)
- A jobb oldalra berakhatjuk az eredményváltozó késleltetettjeit is (itt nyilván egyidejű tagot nem rakhatunk be...), ezzel AR-hatást is létrehozhatunk

### Egy általános modell felé

- Láttuk tehát, hogy a magyarázó változó lehet:
  - Exogén  $z$  (mint a statikus regresszióban)
  - Exogén  $z$  késleltetettje (mint a DL-ben)
  - Az eredményváltozó késleltetettje (mint az AR-ben)
- Külön-külön mindegyiket néztük már – lásd a zárójeles megjegyzéseket – de semmi akadálya, hogy többet (vagy akár az összeset egyszerre) berakjuk egy modellbe!

### Az általános modell

- Mindent összetéve:

$$y_t = \beta_0 + \beta_1 x_{t1} + \beta_2 x_{t2} + \dots + \beta_k x_{tk} + u_t = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}_t + u_t,$$

ahol  $x_{t,i}$  egyaránt *lehet* exogén változó, késleltett exogén változó vagy késleltetett eredményváltozó

- Formailag teljesen olyan, mint a regresszió keresztmetszetben, van eredményváltozó és vannak magyarázóváltozók
- Egyszerűen behúzzuk őket egy modellbe – történetesen nem keresztmetszeti adatok, hanem idősorok, de hát az OLS-nek mindegy, számok vannak így is, úgy is – és simán megbecsüljük OLS-sel... jó ötlet ez?
- A következőkben ezzel fogunk foglalkozni: mi történik akkor, ha a  $\beta$ -kat egyszerűen megbecsüljük OLS-sel, milyen feltételek mellett milyen tulajdonságúak lesznek az így kapott becslések?

## 10.2. Idősoros regresszió becslése OLS-sel

### 10.2.1. Standard modellfeltevések

#### A modellfeltevések és szerepük

- A helyzet, és a kérdés teljesen analóg a keresztmetszetnél látottakkal: milyen modellfeltevések mellett garantálhatóak, hogy az OLS szolgáltatja becsléseknek jó tulajdonságaik legyenek?
- Úgy fogjuk végignézni, hogy mindenhol a keresztmetszettel rakjuk párhuzamba
- Ugyanúgy 5 (+1) modellfeltevés lesz

### Linearitás

- Keresztmetszetnél ez volt:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + u$$

és ez igaz mindegyik megfigyelési egységre, és így az egész mintára is:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + u_i$$

- Idősornál *pontosan ugyanez* a feltétel (legfeljebb  $i$  helyett  $t$ -t szokás írni)

### Nincs egzakt multikollinearitás

- Keresztmetszetnél ez volt:

$$\mathbb{P}(\text{rank } \underline{\underline{X}} = k) = 1$$

- Idősornál *pontosan ugyanez* a feltétel

### Szigorú exogenitás

- Keresztmetszetnél, ha trehányak voltunk, ez volt:

$$\mathbb{E}(u_i | \underline{X}_i) = 0,$$

ha precízek, akkor ez:

$$\mathbb{E}(u_i | \underline{\underline{X}}) = 0$$

- Idősornál, ha precízek voltunk, *pontosan ugyanez* a feltétel
- Tehát: *minden* időszaki hiba várható érték független *minden* (akár más időszaki!) magyarázó változótól

### Szigorú és egyidejű exogenitás

- A trehányság azért volt megengedhető, mert ha fae a mintavétel – ami keresztmetszetnél egy elfogadható feltevés lehet – akkor a precíz tényleg a trehányra egyszerűsödik
- Ez teljesen logikus: ha a különböző mintaelemek függetlenek, akkor egy adott időszaki hiba az összes többi időszaki magyarázó változótól nyilván várható érték független lesz, tehát csak az ugyanazon időszakiktól való függetlenséget kell megkövetelni
- Idősornál, mivel a fae mintavétel itt már nem elfogadható általánosságban, ez a trehányság nem lesz megengedhető
- A továbbiakban a  $\mathbb{E}(u_i | \underline{X}_i) = 0$  feltételt **egyidejű exogenitásnak**, az – erősebb –  $\mathbb{E}(u_i | \underline{\underline{X}}) = 0$  feltételt **szigorú (vagy erős) exogenitásnak** nevezzük
- (Most válik érthetővé, hogy a szigorú exogenitás elnevezésben mit jelent a szigorú!)
- A standard modellfeltevésben tehát a szigorú exogenitás szerepel

**A szigorú exogenitás sérülései**

- Természetesen minden, amit keresztmetszetenél is láttunk (pl. kihagyott változó, mérési hiba)
- Itt azonban más okok is lehetnek a háttérben:
  - Rosszul megragadott dinamika: például statikus regressziót becslünk, miközben FDL lenne a helyes
  - Az  $u$ -beli változás nem befolyásolhatja a későbbi  $x$ -et (ez meg hogy lehetne? úgy, ha  $y$  értékei visszahatnak a későbbi  $x$ -kre, például bűnözés regresszálása a rendőri erők létszámával)

**Homoszkedaszticitás**

- Keresztmetszetenél ez volt:

$$\sigma_i^2 := \mathbb{D}^2(u_i \mid \underline{X}) = \sigma^2$$

- Idősornál *pontosan ugyanez* a feltétel

**Autokorrelálatlanság**

- Keresztmetszetenél ez volt: ha fae a mintavétel, akkor automatikusan teljesül, különben

$$\text{cov}(u_i, u_j \mid \underline{X}) = 0$$

minden  $i, j = 1, 2, \dots, n, i \neq j$

- Idősornál *pontosan ugyanez* (az utóbbi) a feltétel

**Hibanormalitás**

- Keresztmetszetenél ez volt:

$$\underline{u} \mid \underline{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$$

- Idősornál *pontosan ugyanez* a feltétel

**Összefoglalva**

- Ha precízen fogalmaztunk, akkor igazából a keresztmetszetenél látott feltételek egy-az-egyben ugyanazok, mint amire itt is szükség van
- Most már elárulható, hogy ez nem véletlen: a precíz fogalmazás *épp* azért kellett, hogy az ott látott dolgok valójában *univerzálisak* legyenek, tehát ne csak keresztmetszetre vonatkozzanak, hanem ugyanúgy idősorra is
- ...ami tulajdonképpen jól érthető is: a tiszta elmélet egységes kell legyen, hiszen a változóknak „mindegy”, hogy ők most idősorok, vagy keresztmetszeti adatok, vagy micsodák

### 10.2.2. Az OLS véges mintás tulajdonságai idősorokra

#### Az OLS véges mintás tulajdonságai idősorokra

- Az első három feltétel teljesülése esetén az OLS szolgáltatta becslések torzítatlanok
- Ha mind az öt feltétel teljesül, akkor az OLS szolgáltatta becslések ezen felül hatásosak is (azaz BLUE-k is)
- Ha mind az öt feltétel teljesül, akkor a  $\sigma^2$  és a hibák kovarianciamátrixának OLS szolgáltatta becslése torzítatlan
- Ha még a hibanormalitás is teljesül, akkor az OLS szolgáltatta becslések eloszlása normális, a  $t$  ( $F$ ) statisztikák nulleloszlásai tényleg  $t$ -k ( $F$ -ek), a szokásos tesztek és a konfidenciaintervallumok validak

#### A keresztmetszeti esethez való viszony

- Mindez lényegében azt jelenti, hogy ezen feltevések teljesülése esetén az idősoros adatokkal *pontosan ugyanúgy* hajthatunk végre regressziót, mintha keresztmetszetiek lennének!
- Persze látni kell, hogy ezek rettentő erős feltevések voltak, a gyakorlatban ritkán teljesülnek

#### Véges (vagy kis-) mintás tulajdonság mivolt

- A tulajdonságoknál nem mondtuk semmit a mintanagyságról: ez azt jelenti, hogy mintanagyságtól függetlenül – azaz minden mintanagyságra – igazak
- Ilyenkor azt szokták mondani, hogy ezek „kis” mintás (véges mintás) tulajdonságok voltak
- (A kismintás elég szerencsétlen elnevezés, hiszen természetesen nagy mintára is igazak, gyakorlati szempontból persze érthető a kifejezés oka)

### 10.2.3. Az OLS nagymintás tulajdonságai idősorokra

#### A nagymintás tulajdonság értelme és szükségessége

- Nagymintás: nem minden  $n$ -re igaz, hanem csak  $\lim_{n \rightarrow \infty}$  értelemben (szokás még aszimptotikus tulajdonságnak is nevezni)
- Fontos, mert a gyakorlatban a véges mintás tulajdonságokhoz tartozó feltételek sokszor nem teljesülnek, de nagy mintát néha van módunk venni, így nagyon lényeges annak vizsgálata, hogy ezzel mit tudunk „kiváltani”
- Igazából már keresztmetszetnél is láttunk egy nagymintás tulajdonságot: amikor azt mondtuk, hogy az első három tulajdonság fennállása esetén az OLS szolgáltatta becslések konzisztensek



**Kitérő: idősorok ergodicitása**

- Egy idősort **ergodikusk** nevezünk, ha az időben távoli tagjai – bármely időpontból indulva – függetlenbe tartanak az időbeni távolságuk növekedtével (aszimptotikusan függetlenek)
- Egy ergodikuss idősorra, ha még stationer is (és így létezik  $\mu$ ) teljesül, hogy

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{i=1}^T Y_i \xrightarrow{\text{m.b.}} \mu$$

- Néha ezzel definiálják az ergodicitást (pontosabban szólva a várható értékben ergodicitást) – ilyenkor a stationaritást meg kell követelni, vagy legalábbis óvatosan eljárni
- (Természetesen mindig definiálhatjuk az  $I_{\{Y_t \in A\}}$  idősort, ilyenkor a várható érték valószínűség lesz)

Az ergodicitás – egy lehetséges! – pontos definíciója: minden korlátos  $f : \mathbb{R}^{k+1} \rightarrow \mathbb{R}$  és  $g : \mathbb{R}^{l+1} \rightarrow \mathbb{R}$  függvényre és minden  $i$ -re igaz, hogy

$$\begin{aligned} \lim_{n \rightarrow \infty} |\mathbb{E}[f(y_i, y_{i+1}, \dots, y_{i+k}) g(y_{i+n}, y_{i+n+1}, \dots, y_{i+n+l})]| &= \\ = |\mathbb{E}[f(y_i, y_{i+1}, \dots, y_{i+k})]| |\mathbb{E}[g(y_{i+n}, y_{i+n+1}, \dots, y_{i+n+l})]|. \end{aligned}$$

**Az ergodicitás tartalma**

- Lényegében azt mondja ki, hogy időátlag tart a sokasági – összességi – átlaghoz:
  - Azért fontos, mert azt mondja, hogy elég sok elemet megfigyelve (az időben – ugye mi csak ezt tudjuk megtenni!) *tényleg* tudunk következtetni a várható értékekre/valószínűségekre (ami igazából érdekel minket!)
  - A nagy számok törvényének megfelelője, illetve általánosítása (nem kellett a teljes függetlenséget feltenni)
- Néha szokás ezt gyenge függőségnek is nevezni

**Ergodicitás és az autokovarianciák**

- Érezhető, hogy ha egyszer az ergodicitás olyasmit követel meg, hogy az egyre távolabbi értékek egyre függetlenebbek legyenek (a teljes függetlenséghez tartva), akkor összefügg az autokovarianciákkal – hiszen azok is valami függetlenséggel kapcsolatban lévő dolgot mérnek
- Csakugyan, belátható, hogy egy idősor ergodikuss (a várható értékre), ha a kovarianciái nullába tartanak, mégpedig olyan gyorsan, hogy abszolút összegezhetőek is:

$$\sum_{i=1}^{\infty} |\gamma_i| < \infty$$

### Stacionaritás és ergodicitás

- Egy stacioner idősor nem feltétlenül ergodikus:  $Y_t = X$  (ahol  $X$  egy valószínűségi változó), azaz az idősor konstans
- Egy ergodikus idősor nem feltétlenül stacioner:  $Y_t = \alpha t + u_t$ , ahol  $\alpha \neq 0$  és  $u_t \sim \mathcal{N}(0, \sigma_u^2)$  függetlenül
- Nagyon sok esetben azonban a kettő ugyanaz (néhol keveredés is van emiatt a szóhasználatban)

### Az új modellfeltevések

- Pluszban megköveteljük a linearitásnál, hogy az idősorok legyenek stacionerek és ergodikusak is
- Cserében viszont
  - Szigorú (erős) exogenitás helyett elég lesz az egyidejű exogenitás:  $\mathbb{E}(u_i | \underline{X}_i) = 0$
  - Szigorú (erős) homoszkedaszticitás helyett elég lesz az egyidejű homoszkedaszticitás:  $\mathbb{D}^2(u_i | \underline{X}_i) = \sigma^2$
  - Szigorú (erős) autokorrelálatlanság helyett elég lesz az egyidejű autokorrelálatlanság:  $\text{cov}(u_i, u_j | \underline{X}_i, \underline{X}_j) = 0$
- (A hibanormalitásról nem tettünk fel semmit: nem kellett, mert úgyis aszimptotikus eredményeink lesznek, ahol a centrális határeloszlás tétel kihasználható – ugyanis a fenti feltételek mellett az is működni fog, nem csak a nagy számok törvénye)

### Az OLS nagymintás tulajdonságai

- Az előbb vázolt modellfeltevések közül az első három teljesülése esetén az OLS szolgáltatta becslések konzisztensek
- Ha mind az öt teljesül, akkor az OLS szolgáltatta becslések aszimptotikusan normálisak, a  $t$  ( $F$ ) statisztikák nulleloszlásai tényleg  $t$ -k ( $F$ -ek) aszimptotikusan, a szokásos tesztek és a konfidenciaintervallumok aszimptotikusan validak